

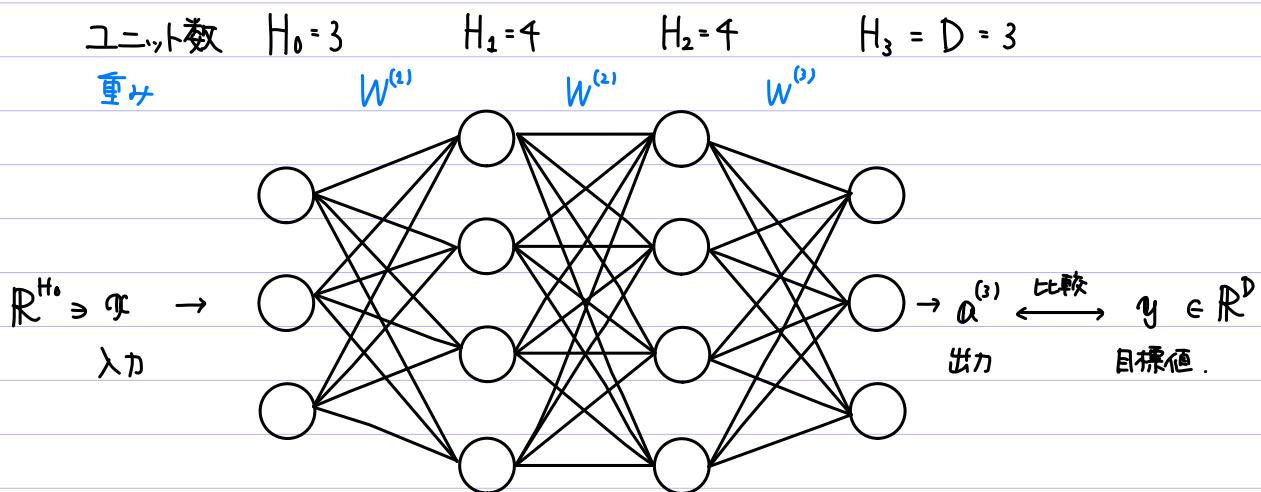
Ch.5 ニューラルネットワークの Bayes 推論.

- Feedforward NN 等の深層学習モデルで Bayes 的に扱って、

Ch.4 でやった近似推論手法で NN モデルに適用していく。

用語・記法の復習 (Ch.2 など)

順伝播型ニューラルネットワーク (feedforward NN)



入力層 layer 0	隠れ層 layer 1	出力層 layer 3	層数 $L = 3$
----------------	----------------	----------------	---------------

各層の出力 : $\mathbf{z}^{(0)} = x$, $\mathbf{z}^{(l)} = \phi(a^{(l)}) \quad (l=1, \dots, L-2)$

活性化函数 (非線形)
要素ごとの適用.

活性 : $a^{(l)} = W^{(l)} \mathbf{z}^{(l-1)} \quad (l=1, \dots, L)$

重みの各要素を全てまとめて W を書く。一括りにして扱う。

重み W はパラメータとする NN を $f(x; W)$ と表す。 $f(x; W) = a^{(L)}$.

§5.1 Bayes ニューラルネットワークモデルの近似推論法.

- ・ NN の学習 (全データ一度に学習) に比べる.
- ・ 回帰問題を扱う. (分類でも本筋は同じ)

5.1.1 Bayes ニューラルネットワークモデル

- ・ ネットワークの挙動を支配するパラメータ W の事前分布 $p(W)$ を設定すること.

Bayes 的に扱えるようとする.

入力 $X = \{x_1, \dots, x_N\}$ に対する観測データ $Y = \{y_1, \dots, y_N\}$: given.

- ・ モデルを次のように設定:

$$p(Y, W | X) = p(W)p(Y | X, W) = p(W) \prod_{n=1}^N p(y_n | x_n, W)$$

$$\text{観測モデル: } p(y_n | x_n, W) = \mathcal{N}(y_n | f(x_n; W), \sigma_y^2 I_D)$$

$$(\sigma_y^2 > 0 \text{ は固定のノイズパラメータ})$$

$$\text{事前分布: } p(W) = \prod_{w \in W} p(w) = \prod_{w \in W} \mathcal{N}(w | 0, \sigma_w^2)$$

$$(\sigma_w^2 > 0 \text{ は固定のノイズパラメータ})$$

以下では、簡単のため出力次元を $D = 1$ で考える.

5.1.2 Laplace 近似による学習.

5.1.2.1 事後分布の近似

1. 事後分布 $p(W | Y, X)$ の最大化問題の局所最適解 \tilde{W} を求める.

\tilde{W} は $p(W | Y, X)$ の局所最適解であるから、

\tilde{W} は $\log p(W|Y, X)$ の局所最適解である。

- $\log p(W|Y, X)$ に対して勾配降下法で最小化すれば、

- $\log p(W|Y, X)$ の極小解 $\Leftrightarrow \log p(W|Y, X)$ の極大解 が得られる。

反復スキーム：学習率 $\epsilon \alpha > 0$ とし、

$$W_{\text{new}} \leftarrow W_{\text{old}} + \alpha D_W \log p(W|Y, X) \Big|_{W=W_{\text{old}}}.$$

• $D_W \log p(W|Y, X) = \left(\frac{\partial}{\partial w} \log p(W|Y, X) \right)_{w \in W}$ とし、

$$p(W|Y, X) \propto p(W)p(Y|X, W) \quad \text{← } W \text{ に依存する項のみ考慮}$$

$$\log p(W|Y, X)$$

$$= \log p(Y|X, W) + \log p(W) + \text{const.}$$

$$= \sum_{n=1}^N \log \mathcal{N}(y_n | f(x_n; W), \sigma_y^2) + \sum_{w \in W} \log \mathcal{N}(w | 0, \sigma_w^2) + \text{const.}$$

各項は、

$$\log \mathcal{N}(y_n | f(x_n; W), \sigma_y^2) = -\frac{1}{2\sigma_y^2} (y_n - f(x_n; W))^2 + \text{const.}$$

$$\log \mathcal{N}(w | 0, \sigma_w^2) = -\frac{w^2}{2\sigma_w^2} + \text{const.}$$

たとえ、パラメータ $w \in W$ を微分すると、

$$\frac{\partial}{\partial w} \log p(W|Y, X)$$

$$= -\frac{1}{\sigma_y^2} \frac{\partial}{\partial w} \left(\frac{1}{2} \sum_{n=1}^N (y_n - f(x_n; W))^2 \right) - \frac{1}{\sigma_w^2} \frac{\partial}{\partial w} \left(\frac{1}{2} \sum_{w \in W} w^2 \right)$$

$$=: E(W) \qquad \qquad \qquad =: \Omega_{L2}(W)$$

$$= -\left(\frac{1}{\sigma_y^2} \frac{\partial}{\partial w} E(W) + \frac{1}{\sigma_w^2} \frac{\partial}{\partial w} \Omega_{L2}(W) \right).$$

$= w$

$$\nabla_w \log p(w|y, x) = -\left(\frac{1}{\sigma_y^2} \nabla_w E(w) + \frac{1}{\sigma_w^2} w\right).$$

- 第1項は backpropagation で計算できる。

$$\rightarrow \text{スティーブンソン} \quad W_{\text{new}} \leftarrow W_{\text{old}} + \alpha \nabla_w \log p(w|y, x) \Big|_{w=W_{\text{old}}} \text{ はさむと計算できる}.$$

- $p(w|y, x) \approx q(w) = \mathcal{N}(w|\tilde{w}, (\Lambda(\tilde{w}))^{-1})$ と近似。

精度行列は、

$$\Lambda(\tilde{w}) = -\nabla_w^2 \log p(w|y, x) = \frac{1}{\sigma_y^2} \nabla_w^2 E(w) + \frac{1}{\sigma_w^2} I$$

Hesse行列。

5.1.2.2 予測分布の近似

- 次は予測分布 $p(y_*|x_*, y, x) = \int p(y_*|x_*, w)p(w|y, x) dw$

の近似とする。上の事後分布の近似 $p(w|y, x) \approx q(w)$ を使う。

- $p(y_*|x_*, w) = \mathcal{N}(y_*|f(x_*; w), \sigma_y^2)$ で、NN $f(x_*; w)$ が含まれる。

事後分布の近似としても依然として解析的に計算できない。

→ パラメータの事後分布の密度が \tilde{w} ばかりに集中している。
サンプル数が多ければ?
精度は妥当吗?

この近傍で $f(x_*; w) \in \mathcal{W}$ の関して線形近似でまとめて仮定。

Taylor展開で 1 次近似：

$$f(x_*; w) \approx f(x_*; \tilde{w}) + \left(\nabla_w f(x_*; w) \Big|_{w=\tilde{w}} \right)^T (w - \tilde{w}).$$

$\therefore g$

- 結果、予測分布は次のよう近似する。

$$\begin{aligned} & p(y_*|x_*, y, x) \\ & \approx \int \mathcal{N}(y_*|f(x_*; \tilde{w}) + g^T(w - \tilde{w}), \sigma_y^2) \mathcal{N}(w|\tilde{w}, (\Lambda(\tilde{w}))^{-1}) dw. \end{aligned}$$

これΣ計算ル♂). $f = f(x_*; \tilde{W})$ と書く。

$$\log \mathcal{N}(y_* | f + g^T(\mathbf{w} - \tilde{\mathbf{w}}), \sigma_y^2)$$

$$= -\frac{1}{2\sigma_y^2} (y_* - (f + g^T(\mathbf{w} - \tilde{\mathbf{w}})))^2 + \text{const.}$$

$$= -\frac{1}{2\sigma_y^2} (y_*^2 - 2(f + g^T(\mathbf{w} - \tilde{\mathbf{w}}))y_* + (f + g^T(\mathbf{w} - \tilde{\mathbf{w}}))^2) + \text{const.}$$

$$= -\frac{1}{2\sigma_y^2} (y_*^2 - 2(f - g^T \tilde{\mathbf{w}})y_* + (f - g^T \tilde{\mathbf{w}})^2 - 2g^T \mathbf{w} y_* + 2g^T \mathbf{w} (f - g^T \tilde{\mathbf{w}}) + (g^T \mathbf{w})^2) + \text{const.}$$

$$= -\frac{1}{2\sigma_y^2} (y_* - (f - g^T \tilde{\mathbf{w}}))^2 - \frac{1}{2\sigma_y^2} (\mathbf{w}^T g g^T \mathbf{w} - 2\mathbf{w}^T g (y_* - (f - g^T \tilde{\mathbf{w}}))) + \text{const.}$$

したがって、

$$\log \mathcal{N}(\mathbf{w} | \tilde{\mathbf{w}}, (\Lambda(\tilde{\mathbf{w}}))^{-1})$$

$$= -\frac{1}{2} (\mathbf{w} - \tilde{\mathbf{w}})^T \Lambda(\tilde{\mathbf{w}}) (\mathbf{w} - \tilde{\mathbf{w}}) + \text{const.}$$

$$= -\frac{1}{2} (\mathbf{w}^T \Lambda(\tilde{\mathbf{w}}) \mathbf{w} - 2\mathbf{w}^T \Lambda(\tilde{\mathbf{w}}) \tilde{\mathbf{w}}) + \text{const.}$$

これが♂'。

$$\log \mathcal{N}(y_* | f + g^T(\mathbf{w} - \tilde{\mathbf{w}}), \sigma_y^2) \mathcal{N}(\mathbf{w} | \tilde{\mathbf{w}}, (\Lambda(\tilde{\mathbf{w}}))^{-1})$$

$$= -\frac{1}{2\sigma_y^2} (y_* - (f - g^T \tilde{\mathbf{w}}))^2$$

$$- \frac{1}{2} \left(\mathbf{w}^T \left(\Lambda(\tilde{\mathbf{w}}) + \frac{1}{\sigma_y^2} g g^T \right) \mathbf{w} - 2\mathbf{w}^T \left(\Lambda(\tilde{\mathbf{w}}) \tilde{\mathbf{w}} + \frac{1}{\sigma_y^2} g (y_* - (f - g^T \tilde{\mathbf{w}})) \right) \right) + \text{const.}$$

$$= \log \mathcal{N}(y_* | f - g^T \tilde{\mathbf{w}}, \sigma_y^2) - \frac{1}{2} (\mathbf{w}^T \Lambda_* \mathbf{w} - 2\mathbf{w}^T \Lambda_* \mathcal{M}(y_*)) + \text{const.}$$

$$= \log \mathcal{N}(y_* | f - g^T \tilde{\mathbf{w}}, \sigma_y^2) - \frac{1}{2} (\mathbf{w} - \mathcal{M}(y_*))^T \Lambda_* (\mathbf{w} - \mathcal{M}(y_*)) + \frac{1}{2} \mathcal{M}(y_*)^T \Lambda_* \mathcal{M}(y_*) + \text{const.}$$

$$= \log \mathcal{N}(y_* | f - g^T \tilde{\mathbf{w}}, \sigma_y^2) \mathcal{N}(\mathbf{w} | \mathcal{M}(y_*), \Lambda_*^{-1}) + \frac{1}{2} \mathcal{M}(y_*)^T \Lambda_* \mathcal{M}(y_*) + \text{const.}$$

これが♂'。

$$\begin{aligned}
& \int \mathcal{N}(y_* | f + g^\top (\mathbf{w} - \tilde{\mathbf{w}}), \sigma_y^2) \mathcal{N}(\mathbf{w} | \tilde{\mathbf{w}}, (\Lambda(\tilde{\mathbf{w}}))^{-1}) d\mathbf{w} \\
& \propto \mathcal{N}(y_* | f - g^\top \tilde{\mathbf{w}}, \sigma_y^2) \exp\left(\frac{1}{2} \mathcal{M}(y_*)^\top \Lambda_* \mathcal{M}(y_*)\right) \underbrace{\int \mathcal{N}(\mathbf{w} | \mathcal{M}(y_*), \Lambda_*^{-1}) d\mathbf{w}}_{=1} \\
& = \mathcal{N}(y_* | f - g^\top \tilde{\mathbf{w}}, \sigma_y^2) \exp\left(\frac{1}{2} \mathcal{M}(y_*)^\top \Lambda_* \mathcal{M}(y_*)\right).
\end{aligned}$$

∴ て、

$$\begin{aligned}
& \mathcal{M}(y_*)^\top \Lambda_* \mathcal{M}(y_*) \\
& = (\Lambda(\tilde{\mathbf{w}}) \tilde{\mathbf{w}} + \frac{1}{\sigma_y^2} g (y_* - (f - g^\top \tilde{\mathbf{w}})))^\top (\Lambda(\tilde{\mathbf{w}}) + \frac{1}{\sigma_y^2} gg^\top)^{-1} (\Lambda(\tilde{\mathbf{w}}) \tilde{\mathbf{w}} + \frac{1}{\sigma_y^2} g (y_* - (f - g^\top \tilde{\mathbf{w}}))).
\end{aligned}$$

て、 Sherman-Morrison-Woodbury (スル' フ)

$$\begin{aligned}
& (\Lambda(\tilde{\mathbf{w}}) + \frac{1}{\sigma_y^2} gg^\top)^{-1} \quad \text{スカラ-なつて"これに付だ"の逆数} \\
& = \Lambda(\tilde{\mathbf{w}})^{-1} - \frac{1}{\sigma_y^2} \Lambda(\tilde{\mathbf{w}})^{-1} g \underbrace{(1 + \frac{1}{\sigma_y^2} g^\top \Lambda(\tilde{\mathbf{w}})^{-1} g)}_{\curvearrowleft}^{-1} g^\top \Lambda(\tilde{\mathbf{w}})^{-1} \\
& = \Lambda(\tilde{\mathbf{w}})^{-1} - \underbrace{(\sigma_y^2 + g^\top \Lambda(\tilde{\mathbf{w}})^{-1} g)^{-1}}_{=: \sigma(x_*)^{-2}} \Lambda(\tilde{\mathbf{w}})^{-1} gg^\top \Lambda(\tilde{\mathbf{w}})^{-1} \\
& = \Lambda(\tilde{\mathbf{w}})^{-1} (\Lambda(\tilde{\mathbf{w}}) - \sigma(x_*)^{-2} gg^\top) \Lambda(\tilde{\mathbf{w}})^{-1}
\end{aligned}$$

∴ て、

$$\begin{aligned}
& \mathcal{M}(y_*)^\top \Lambda_* \mathcal{M}(y_*) \\
& = (\tilde{\mathbf{w}} + \sigma_y^{-2} \Lambda(\tilde{\mathbf{w}})^{-1} g (y_* - (f - g^\top \tilde{\mathbf{w}})))^\top (\Lambda(\tilde{\mathbf{w}}) - \sigma(x_*)^{-2} gg^\top) (\tilde{\mathbf{w}} + \sigma_y^{-2} \Lambda(\tilde{\mathbf{w}})^{-1} g (y_* - (f - g^\top \tilde{\mathbf{w}}))) \\
& = \tilde{\mathbf{w}}^\top (\Lambda(\tilde{\mathbf{w}}) - \sigma(x_*)^{-2} gg^\top) \tilde{\mathbf{w}} + 2\sigma_y^{-2} \tilde{\mathbf{w}}^\top (\Lambda(\tilde{\mathbf{w}}) - \sigma(x_*)^{-2} gg^\top) \Lambda(\tilde{\mathbf{w}})^{-1} g (y_* - (f - g^\top \tilde{\mathbf{w}})) \\
& \quad \text{const.} \\
& \quad + \sigma_y^{-4} (y_* - (f - g^\top \tilde{\mathbf{w}}))^2 g^\top \Lambda(\tilde{\mathbf{w}})^{-1} (\Lambda(\tilde{\mathbf{w}}) - \sigma(x_*)^{-2} gg^\top) \Lambda(\tilde{\mathbf{w}})^{-1} g \\
& = 2\sigma_y^{-2} g^\top \tilde{\mathbf{w}} \underbrace{(1 - \sigma(x_*)^{-2} g^\top \Lambda(\tilde{\mathbf{w}})^{-1} g)}_{= \sigma_y^2 \sigma(x_*)^{-2}} (y_* - (f - g^\top \tilde{\mathbf{w}})) \\
& \quad + \sigma_y^{-4} (y_* - (f - g^\top \tilde{\mathbf{w}}))^2 g^\top \Lambda(\tilde{\mathbf{w}})^{-1} g \underbrace{(1 - \sigma(x_*)^{-2} g^\top \Lambda(\tilde{\mathbf{w}})^{-1} g)}_{\sigma_y^2 \sigma(x_*)^{-2}} + \text{const.}
\end{aligned}$$

$$= 2\sigma(x_*)^{-2} g^\top \tilde{w} (y_* - (f - g^\top \tilde{w})) + (\sigma_y^{-2} - \sigma(x_*)^{-2}) (y_* - (f - g^\top \tilde{w}))^2 + \text{const.}$$

結局，

$$\begin{aligned}
 & \log \mathcal{N}(y_* | f - g^\top \tilde{w}, \sigma_y^2) \exp\left(\frac{1}{2} \mathcal{M}(y_*)^\top \Lambda_* \mathcal{M}(y_*)\right) \\
 &= -\frac{1}{2} \sigma_y^{-2} (y_* - (f - g^\top \tilde{w}))^2 \\
 &\quad + \frac{1}{2} (2\sigma(x_*)^{-2} g^\top \tilde{w} (y_* - (f - g^\top \tilde{w})) + (\sigma_y^{-2} - \sigma(x_*)^{-2}) (y_* - (f - g^\top \tilde{w}))^2) + \text{const.} \\
 &= -\frac{1}{2} \sigma(x_*)^{-2} ((y_* - (f - g^\top \tilde{w}))^2 - 2g^\top \tilde{w} (y_* - (f - g^\top \tilde{w}))) + \text{const.} \\
 &= -\frac{1}{2} \sigma(x_*)^{-2} (y_*^2 - 2f y_*) + \text{const.} \\
 &= \log \mathcal{N}(y_* | f(x_*; \tilde{w}), \sigma(x_*)) + \text{const.} \\
 &\quad \text{由 } \sigma_y^2 + g^\top \Lambda(\tilde{w})^{-1} g
 \end{aligned}$$

$$p(y_* | x_*, y, \tilde{w}) \approx \mathcal{N}(y_* | f(x_*; \tilde{w}), \sigma_y^2 + g^\top \Lambda(\tilde{w})^{-1} g)$$

5.1.3 ハミルトニアンモンテカルロ法による学習.

- HMCで $p(\boldsymbol{w} | \boldsymbol{y}, \boldsymbol{x})$ からサンプリングをする。

→ サンプリングでは \boldsymbol{w} を使って $y_* = f(x_*; \boldsymbol{w})$ と予測をする。

複数回サンプリングすれば、予測の不確実性もわかる。

- 離散変数をパラメータに含まないなら、 $\nabla_{\boldsymbol{w}} \log p(\boldsymbol{w} | \boldsymbol{y}, \boldsymbol{x})$ の計算は

backpropagation でできる。

→ ポテンシャルの微分ができるなら HMC が使える

- 計算時間は比較的長いものの、理論的には真の事後分布からのサンプルが得られる。

5.1.3.1 重みパラメータの推論.

$$\log p(\boldsymbol{w} | \boldsymbol{y}, \boldsymbol{x}) = \log p(\boldsymbol{y} | \boldsymbol{x}, \boldsymbol{w}) + \log p(\boldsymbol{w}) + \text{const. term},$$

$$\text{ポテンシャルエネルギー } U(\boldsymbol{w}) = -\log p(\boldsymbol{y} | \boldsymbol{x}, \boldsymbol{w}) - \log p(\boldsymbol{w})$$

を利用する。

1) フロッグ法で、この微分が必要になる (backpropagation でできる)

- NNに対する HMC の適用に関する問題点。

✗ 複雑な分布からのサンプリング: なるほど、「」ないサンプリング数では分布の特徴を

とらえきれていないとどうも不明。適切なサンプリング数も不明。

✗ ステップサイズ ϵ やステップ数 L の調整が難しい。

✗ 学習が遅い。

5.1.3.2 ハイパ-パラメータの推論.

- 上では σ_w^2 , σ_y^2 をハイパ-パラメータとして扱ってきた。

これにも事前分布を与えること、推論で使うとする。

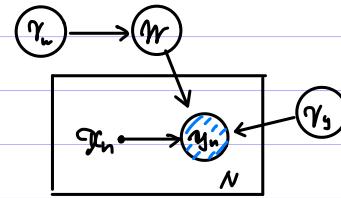
- 以下、精度パラメータ $\gamma_w = \sigma_w^{-2}$, $\gamma_y = \sigma_y^{-2}$ を利用する。

事前分布: $p(\gamma_w) = \text{Gam}(\gamma_w | a_w, b_w)$ ← ガンマ分布は $\gamma_w > 0$ で確率が非ゼロ。正の実数と0値の分布として使う。

$$p(\gamma_y) = \text{Gam}(\gamma_y | a_y, b_y)$$

$(a_w, b_w, a_y, b_y > 0 : \text{固定値})$

- モテ。



$$p(Y, M, \gamma_w, \gamma_y | \mathcal{E}) = p(\gamma_w) p(\gamma_y) p(M | \gamma_w) \prod_{n=1}^N p(y_n | x_n, M, \gamma_y)$$

- 事後分布は、 $p(M, \gamma_w, \gamma_y | Y, \mathcal{E})$.

- Gibbsサンプリングをする。

• γ_w, γ_y : given として、 M の条件付き分布は $p(M | Y, \mathcal{E}, \gamma_w, \gamma_y)$.

これは M の事後分布なので、HMCで M をサンプリングできる

• M, γ_y : given として、 γ_w の条件付き分布は、

$$p(\gamma_w | Y, \mathcal{E}, M, \gamma_y)$$

$$\propto p(Y, M, \gamma_y, \gamma_w | \mathcal{E})$$

$$\propto p(M | \gamma_w) p(\gamma_w).$$

$p(M | \gamma_w)$ は Gauss 分布、 $p(\gamma_w)$ はその先駆事前分布のガンマ分布なので、

条件付き分布 $p(\gamma_w | \gamma_y, \mathcal{F}, W, \gamma_y)$ は ガンマ分布. $K_w := (W \text{ の } 1^{\text{st}} - \text{ラグ})$ とし,

Ch.3 での結果より

$$\gamma_w \sim \text{Gam}(\hat{a}_w, \hat{b}_w), \quad \hat{a}_w = a_w + \frac{1}{2} K_w, \quad \hat{b}_w = b_w + \frac{1}{2} \sum_{w \in W} w^2$$

とサンプリングすればよい.

• W, γ_w : given とし. γ_y の条件付き分布は,

$$p(\gamma_y | \gamma_y, \mathcal{F}, W, \gamma_w)$$

$$\propto p(\gamma_y, W, \gamma_y, \gamma_w | \mathcal{F})$$

$$\propto p(\gamma_y) p(\gamma_y | \mathcal{F}, W, \gamma_y).$$

$p(\gamma_y | \mathcal{F}, W, \gamma_y)$ は Gauss 分布で, $p(\gamma_y)$ は ガンマ 分布なので,

$p(\gamma_y | \gamma_y, \mathcal{F}, W, \gamma_w)$ も ガンマ 分布.

∴ $\gamma_y \sim \text{Gam}(\hat{a}_y, \hat{b}_y)$,

$$\hat{a}_y = a_y + \frac{1}{2} N,$$

$$\hat{b}_y = b_y + \frac{1}{2} \sum_{n=1}^N (y_n - f(x_n; W))^2 = b_y + E(W).$$

現在の W で表現できない NN の誤差の情報と
バイアスパラメータに加味している。

・ ガンマ 分布の 平均 : $E[\gamma_y] = \frac{\hat{a}_y}{\hat{b}_y}$

→ \hat{b}_y 越しだい \Leftrightarrow 誤差 $E(W)$ 越しだい.

γ_y の逆数

このとき $E[\gamma_y]$ は 小さくなるので, y_n に対する分數は大きくなる

・ 重みの $1/110 - 1^{\text{st}} - \text{ラグ} - \text{タ}$ γ_w は 共通 と して いたが, 層ごとに $1^{\text{st}} - \text{ラグ} - \text{タ}$ を 变える, など、
改変もできる。

§5.2 近似 Bayes 推論の効率化

- Bayes NN :

✗ パラメータの固近代化に伴う計算量が膨大。

学習に必要なデータ数が多い

→ ✗ バッチ学習は効率が良くない。

- 巨大なネットワークや膨大なデータ量に対しても、近似的な Bayes 推論ができるようとする。

Q ミニバッチを利用した効率的な学習。

5.2.1 確率的勾配 Langevin 動力学法による学習

- SGD

✓ 大規模な NN モデルの効率的な学習。

✗ 正則化項を追加した最適化や MAP 推定などでは、
点推定

パラメータの不確実性を取り扱えない。

→ 過適合を防ぐ。

不確実性に基づく予測やモデルの評価ができるない。

- HMC ← 勾配を利用してサンプリング方法

・ 上述と同様

✗ (MCMC 全般的に) 大規模データに対する計算効率が悪い。

・確率的勾配 Langevin 動力学法

(Stochastic gradient Langevin dynamics method)

- SGD + Langevin dynamics method

✓ 計算効率が高い。

✓ 不確定性の推定が可能。

・確率的 MCMC の一種。

- SGD のアルゴリズムを用いて、NN の正則化項付きのコスト函数を最適化。

ミニバッチを指定する添字集合を δ と書く。 $|\delta| = M$.

ミニバッチ : $D_\delta = \{(x_n, y_n)\}_{n \in \delta}$.

$X_\delta := \{x_n\}_{n \in \delta}$, $y_\delta := \{y_n\}_{n \in \delta}$

MAP 推定

$$W_{MAP} = \underset{W}{\operatorname{argmax}} \log p(W | Y_\delta, X_\delta)$$

即ち 正則化項付きのコスト函数の最小化と等価だ。T=

$$\nabla_W \log p(W | Y_\delta, X_\delta)$$

W : 依存する

$$= \nabla_W \log p(Y_\delta | W, X_\delta) + \nabla_W \log p(W) - \nabla_W \log p(Y_\delta | X_\delta)$$

$$= \sum_{n \in \delta} \nabla_W \log p(y_n | x_n, W) + \nabla_W \log p(W).$$

つまり、ミニバッチに対するコスト函数が、期待値としては全データに対する

コスト函数と等価となるよう係数を調整すると、

⑦ 回目のパラメータの更新は

$$\mathcal{W} \leftarrow \mathcal{W} + \frac{\alpha_t}{2} \left(\frac{N}{M} \sum_{n=1}^N \nabla_{\mathcal{W}} \log p(y_n | x_n, \mathcal{W}) + \nabla_{\mathcal{W}} \log p(\mathcal{W}) \right)$$

係数は便宜上こう設定する

とすればよい。学習率 α_t は収束解への収束が保証された。

$$\sum_{i=1}^{\infty} \alpha_i = \infty, \quad \sum_{i=1}^{\infty} \alpha_i^2 < \infty$$

とみたうえでとする。

・ Langevin 動力学法で事後分布 $p(\mathcal{W} | y, \mathcal{X})$ のサンプル候補 \mathcal{W}^* を得る。

$$\text{ポテンシャルエネルギー } \mathcal{U} = -\log p(\mathcal{W} | y, \mathcal{X}),$$

運動量ベクトルを $\mathbf{p} \sim \mathcal{N}(\mathbf{p} | 0, \mathbf{I})$ とし、

$$\text{ステップサイズ } \varepsilon = \sqrt{\alpha_t} \text{ とする},$$

$$\begin{aligned} \mathcal{W}^* &= \mathcal{W} - \frac{\varepsilon^2}{2} \nabla_{\mathcal{W}} \mathcal{U} + \varepsilon \mathbf{p} \\ &= \mathcal{W} + \frac{\alpha_t}{2} \left(\sum_{n=1}^N \nabla_{\mathcal{W}} \log p(y_n | x_n, \mathcal{W}) + \nabla_{\mathcal{W}} \log p(\mathcal{W}) \right) + \sqrt{\alpha_t} \mathbf{p}. \end{aligned}$$

・ \mathcal{W}^* の受容率は、 ε が小さく (i.e., α_t が小さく) ほど高いと近づく。
シミュレーション結果が小さくなる。

・ 上の二つのアプローチで、Langevin 動力学法のミニバッチ版で

$$\begin{aligned} \mathcal{W} &\leftarrow \mathcal{W} + \frac{\alpha_t}{2} \left(\frac{N}{M} \sum_{n=1}^N \nabla_{\mathcal{W}} \log p(y_n | x_n, \mathcal{W}) + \nabla_{\mathcal{W}} \log p(\mathcal{W}) \right) + \sqrt{\alpha_t} \mathbf{p} \\ \mathbf{p} &\sim \mathcal{N}(\mathbf{p} | 0, \mathbf{I}) \end{aligned}$$

とする。

✓ $\nabla_{\mathcal{W}} \log p(\mathcal{W} | y, \mathcal{X})$ の不偏推定量が得られる。

✓ $t \rightarrow \infty$ でサンプル \mathcal{W} の受容率が漸近的に 1。

\Rightarrow はじめに SGD の利点を生かして \mathcal{W} を効率的に探索。

ただし大きさ T ほど \mathcal{W} で Langevin 动力学法による真の重分布から、

近似的なサンプルを得ることでできるようになります。

5.2.2 確率的変分推論法による学習

- 確率的変分推論法 (Stochastic variational inference method)

SGD + 変分推論 \rightarrow 効率的学習

- $p(\mathcal{W} | \mathcal{Y}, \mathcal{X}) \approx q(\mathcal{W}; \xi)$ と近似。

$$\text{ここで}, \xi = \{\mu_{i,j}^{(t)}, \sigma_{i,j}^{(t)2}\}_{i,j,t} \text{ で } q(\mathcal{W}; \xi) = \prod_{i,j,t} \mathcal{N}(w_{i,j}^{(t)} | \mu_{i,j}^{(t)}, \sigma_{i,j}^{(t)2}) \text{ とす。}$$

ELBO は、

$$\begin{aligned} \mathcal{L}(\xi) &= \int q(\mathcal{W}; \xi) \log \frac{p(\mathcal{W}, \mathcal{Y} | \mathcal{X})}{q(\mathcal{W}; \xi)} d\mathcal{W} \\ &= \int q(\mathcal{W}; \xi) \left(\log \frac{p(\mathcal{Y} | \mathcal{W}, \mathcal{X})}{q(\mathcal{W}; \xi)} + \log p(\mathcal{W}) \right) d\mathcal{W} \\ &= \int q(\mathcal{W}; \xi) \log p(\mathcal{Y} | \mathcal{W}, \mathcal{X}) d\mathcal{W} - D_{KL}[q(\mathcal{W}; \xi) \| p(\mathcal{W})] \\ &= \sum_{n=1}^N \int q(\mathcal{W}; \xi) \log p(y_n | f(x_n; \mathcal{W})) d\mathcal{W} - D_{KL}[q(\mathcal{W}; \xi) \| p(\mathcal{W})]. \end{aligned}$$

- $\mathcal{L}(\xi)$ を勾配降下法で ξ について最大化しようとすると、各ステップごとの

$\nabla_\xi \mathcal{L}(\xi)$ の評価のために全データを読みこむ必要がある。

\rightarrow 効率的でない。

- ミニバッチ \mathcal{D}_s に対する部分的な ELBO を以下のように設定:

$$\mathcal{L}_s(\xi) = \frac{N}{M} \sum_{n \in s} \int q(\mathcal{W}; \xi) \log p(y_n | f(x_n; \mathcal{W})) d\mathcal{W} - D_{KL}[q(\mathcal{W}; \xi) \| p(\mathcal{W})].$$

$\rightarrow \mathbb{E}_{\xi}[\mathcal{L}_s(\xi)] = \mathcal{L}(\xi)$ (不偏推定量) となる.

(pf. は Ch.2 でやったのと同様.)

$\mathcal{L}(\xi)$ を最大化する代わりに, $\mathcal{L}_s(\xi)$ を最大化するより簡単である.

5.2.3 勾配のモンテカルロ近似.

- $\mathcal{L}_s(\xi)$ に対して勾配降下法を行うには, $\nabla_{\xi} \mathcal{L}_s(\xi)$ を計算する必要がある
 - $\nabla_{\xi} D_{KL}[q(W; \xi) \| p(W)]$ は, たぶん Gauss 分布なので解析的に計算できる
 - $\nabla_{\xi} \int q(W; \xi) \log p(y_n | f(x_n; W)) dW$ は解析的に計算できない.
 - \rightarrow モンテカルロ法で積分を近似し, 勾配の推定を得る.
 - 簡易的に表記する パラメータ $w \in \mathbb{R}$ に対して, ある函数 $f(w)$ と分布 $q(w; \xi)$ を考え, 勾配
- $$I(\xi) = \nabla_{\xi} \int f(w) q(w; \xi) dw$$
- を評価したい.

5.2.3.1 スコア函数推定

- 分布 $q(w; \xi)$ に対して, $\nabla_{\xi} \log q(w; \xi)$ をスコア函数という.

$$\begin{aligned} I(\xi) &= \int f(w) \nabla_{\xi} q(w; \xi) dw \\ &= \int f(w) q(w; \xi) \nabla_{\xi} \log q(w; \xi) dw \\ &= \mathbb{E}_{q(w; \xi)} [f(w) \nabla_{\xi} \log q(w; \xi)]. \end{aligned}$$

↓ 漸分と積分の交換
↑ スコア函数

\rightarrow 分布 $q_p(w; \xi)$ から w を複数サンプリングし, $f(w) \nabla_\xi \log q_p(w; \xi)$ のサンプル平均とすることで $I(\xi)$ を推定できる.

✓ $\nabla_\xi \log q_p(w; \xi)$ の計算でさえも利用できる.

✗ 分散が大きい. \rightarrow 制御变量法 (control variates method) を併用.

5.2.3.2 再パラメータ化勾配.

- 再パラメータ化勾配 (reparametrization gradient)

$w \sim q_p(w; \xi)$ とする限りに, 変分パラメータ ξ の True 分布 $p(\varepsilon)$ が

$\varepsilon \sim p(\varepsilon)$ とサンプリングし, $w = g(\xi; \varepsilon)$ と交換することで w を得る.

$$\begin{aligned} \rightarrow I(\xi) &= \nabla_\xi \int f(g(\xi; \varepsilon)) p(\varepsilon) d\varepsilon \\ &= \int f'(g(\xi; \varepsilon)) (\nabla_\xi g(\xi; \varepsilon)) p(\varepsilon) d\varepsilon \\ &= \mathbb{E}_{p(\varepsilon)} [f'(g(\xi; \varepsilon)) \nabla_\xi g(\xi; \varepsilon)]. \end{aligned}$$

↑ w が q_p に従うように p と g を設定する.

分布 $p(\varepsilon)$ から ε を複数サンプリングし, $f'(g(\xi; \varepsilon)) \nabla_\xi g(\xi; \varepsilon)$ のサンプル平均とすることで $I(\xi)$ を推定できる.

ex) $\xi = \{\hat{\mu}, \hat{\sigma}\}$ とし, $q_p(w; \xi) = \mathcal{N}(w | \hat{\mu}, \hat{\sigma}^2)$ の場合を考え.

$\tilde{\varepsilon} \sim \mathcal{N}(0, 1)$ とし, $\tilde{w} = g(\xi; \varepsilon) = \hat{\mu} + \hat{\sigma} \tilde{\varepsilon}$ とすると

$\tilde{w} \sim \mathcal{N}(w | \hat{\mu}, \hat{\sigma}^2)$ となる.

このとき, $\xi = \{\hat{\mu}, \hat{\sigma}\}$ は隠す勾配.

$$\frac{\partial}{\partial \xi} \int f(w) q_\mu(w; \xi) dw = \int f'(w) q_\mu(w; \xi) dw = \mathbb{E}_{q(w; \xi)} [f'(w)].$$

$$\begin{aligned} \frac{\partial}{\partial \xi} \int f(w) q_\mu(w; \xi) dw &= \int f'(w) \tilde{q}_\mu(w; \xi) dw = \int f'(w) \frac{w - \hat{\mu}}{\hat{\sigma}} q_\mu(w; \xi) dw \\ &= \mathbb{E}_{q(w; \xi)} [f'(w) \frac{w - \hat{\mu}}{\hat{\sigma}}]. \end{aligned}$$

5.2.3.3 再パラメータ化勾配の一般化

- 再パラメータ化勾配

✓ 勾配の分散を小さく抑える傾向がある。

✗ ξ に依存しない $p(\varepsilon)$ をつかないことが多い。

- カーネル分布、ベータ分布などでは、再パラメータ化勾配による勾配推定ができない。
- 一般化再パラメータ化勾配 (generalized reparametrization gradient) :

g は隠す関数と緩めて、 ε の分布に対して ξ の依存性が残るまで許容する ($\varepsilon \sim p(\varepsilon; \xi)$)。

- 陰函数微分 (implicit differentiation) を用いる方法。

• g を求めるのは困難だが、 g^{-1} は容易に得られる ε -ス。

ex) ガンマ分布, Dirichlet分布, von Mises分布, etc.

cf.) von Mises分布 : 角度 $\theta \in [0, 2\pi)$ の分布

$$\text{pdf: } p(\theta) = \frac{1}{2\pi I_0(\beta)} \exp(\beta \cos(\theta - \mu))$$

$$\mu \in [0, 2\pi), \quad \beta \geq 0 : 1^{\circ} \text{ 以上 } 9$$

$$I_j(\beta) = \left(\frac{\beta}{2}\right)^j \sum_{i=0}^{\infty} \frac{1}{i! \Gamma(j+i+1)} \left(\frac{\beta^2}{4}\right)^i \quad (j: \text{次第一種反形 Bessel 関数})$$

・逆変換 $\varepsilon = g^{-1}(\xi, w)$ と ξ について微分

→ g を介さずには期待値の勾配を得られる。

・ w のサンプルを得るには (g が計算できないので) 梯度サンプリングなどと使う必要がある。

・離散の確率変数に対する再パラメータ化勾配を利用する方法もある。

・ Gumbel ソフトマックス分布(連続分布)で、

分布の温度パラメータ $\varepsilon \in (0, 1)$ とすることでカテゴリ分布に一致させることができる。

→ カテゴリ分布の Gumbel ソフトマックス分布による連続緩和ができる。

5.2.4 勾配近似による変分推論法

再パラメータ化勾配を利用して、ミニバッチ $\mathcal{D}_s = \{(x_n, y_n)\}_{n \in s}$ に対する

ELBO

$$\mathcal{L}_s(\xi)$$

$$= \frac{N}{M} \sum_{n \in s} \int q(w; \xi) \log p(y_n | f(x_n; w)) dw - D_{KL}[q(w; \xi) \| p(w)]$$

を最大化する

→ 事後分布の近似精度を上げる。

$\varepsilon \sim \mathcal{N}(0, I)$, $w = g(\xi; \varepsilon)$ の変数変換。

$$q(w; \xi) dw = p(\varepsilon) d\varepsilon \quad \text{∴ 注意して。}$$

$$\mathcal{L}_s(\xi) = \frac{N}{M} \sum_{n \in s} \int p(\varepsilon) \log p(y_n | f(x_n; g(\xi; \varepsilon))) d\varepsilon - D_{KL}[q(w; \xi) \| p(w)].$$

すこい難だけど計算が楽的に
しかもちからず。
大変なので仕方ない。複数サンプリング

積分を、1回のサンプル値 $\tilde{\xi} \sim \mathcal{N}(\xi | 0, I)$ で近似する。

\nwarrow ただし x_n, y_n は独立にサンプリングする

$$\mathcal{L}_s(\xi) \approx \mathcal{L}_{s,\tilde{\xi}}(\xi)$$

$$= \frac{N}{M} \sum_{n \in S} \log p(y_n | f(x_n; g(\xi; \tilde{\xi}))) - D_{KL}[q(w; \xi) \| p(w)]$$

$\mathcal{L}_{s,\tilde{\xi}}(\xi)$ は $\mathcal{L}(\xi)$ の不偏推定量 : $E_{s,\tilde{\xi}}[\mathcal{L}_{s,\tilde{\xi}}(\xi)] = \mathcal{L}(\xi)$.

- 計算すればわかる。
- 勾配を近似すると、

$$\nabla_\xi \mathcal{L}_s(\xi) \approx \nabla_\xi \mathcal{L}_{s,\tilde{\xi}}(\xi)$$

$$= \frac{N}{M} \sum_{n \in S} \nabla_\xi \log p(y_n | f(x_n; g(\xi; \tilde{\xi}))) - \nabla_\xi D_{KL}[q(w; \xi) \| p(w)]$$

\nwarrow backpropagation で計算できる。
解析的に求まる。

まとめと、以下の手順で ξ を最適化する。

- ミニバッチ $D_s \in \mathcal{D}$ をうつくる。
- M 個の 1 イテラーションで $\tilde{\xi}_i \sim \mathcal{N}(0, I)$ を取得。
- $\nabla_\xi \mathcal{L}_{s,\tilde{\xi}}(\xi)$ を計算。
- $\xi \leftarrow \xi + \alpha \nabla_\xi \mathcal{L}_{s,\tilde{\xi}}(\xi)$ と更新。1へ。

5.2.5 期待値伝播法による学習

- 確率的逆伝播法 (probabilistic backpropagation method)

・順伝播：ネットワークを通して確率を伝播、周辺尤度の評価。

・逆伝播：パラメータ学習そのための周辺尤度の勾配計算。

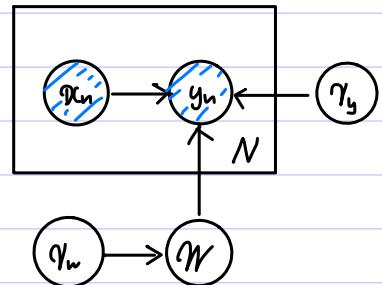
✓ データを逐次的に処理でき、大量データへの学習ができます。

✓ 1111-111x-1の近似推論。

5.2.5.1 モデル

$y_n \in \mathbb{R}$: 1次元のラベルを考える。

モデル :



$$p(y, w, \gamma_y, \gamma_w | \mathcal{X}) = p(y | \mathcal{X}, w, \gamma_y) p(w | \gamma_w) p(\gamma_y) p(\gamma_w).$$

$$p(y | \mathcal{X}, w, \gamma_y) = \prod_{n=1}^N \mathcal{N}(y_n | f(x_n; w), \gamma_y^{-1})$$

$$p(\gamma_y) = \text{Gam}(\gamma_y | \alpha_{\gamma_y 0}, \beta_{\gamma_y 0}) \quad (\alpha_{\gamma_y 0}, \beta_{\gamma_y 0} : 1111-111x-1)$$

$$p(w | \gamma_w) = \prod_{l=1}^L \prod_{i=1}^{H_l} \prod_{j=1}^{H_{l-1}} \mathcal{N}(w_{i,j}^{(l)} | 0, \gamma_w^{-1}) \quad \leftarrow \text{全} \times \text{独立}$$

$$p(\gamma_w) = \text{Gam}(\gamma_w | \alpha_{\gamma_w 0}, \beta_{\gamma_w 0}) \quad (\alpha_{\gamma_w 0}, \beta_{\gamma_w 0} : 1111-111x-1)$$

ここで、NN $f(x_n; w)$ を次のように設定している：

$$z_n^{(0)} = x_n, \quad z_n^{(l)} = \text{ReLU.}(a_n^{(l)}) \quad (l = 1, \dots, L-1)$$

$$a_n^{(l)} = \frac{1}{\sqrt{H_{l-1}}} W^{(l)} z_n^{(l-1)} \quad (l = 1, \dots, L) \quad \leftarrow \text{係数を調整}$$

$$f(x_n; w) = z_n^{(L)} = a_n^{(L)}$$

・ 事後分布

$$p(w, \gamma_y, \gamma_w | y, \mathcal{X})$$

$$\propto \frac{1}{p(y | \mathcal{X})} p(y, w, \gamma_y, \gamma_w | \mathcal{X})$$

$$\propto p(y | \mathcal{X}, w, \gamma_y) p(w | \gamma_w) p(\gamma_y) p(\gamma_w)$$

5.2.5.2 近似分布

- 近似分布を次のとおりに設定（事前分布と同じ種類の分布と選択）：

$$p(W, \gamma_y, \gamma_w | Y, X) \approx q_p(W, \gamma_y, \gamma_w), \quad q_p(w_{ij}^{(t)})$$

$$\begin{aligned} q_p(W, \gamma_y, \gamma_w) &= \frac{\text{Gam}(\gamma_y | \alpha_{\gamma_y}, \beta_{\gamma_y})}{q_p(\gamma_y)} \frac{\text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w})}{q_p(\gamma_w)} \prod_{j=1}^L \prod_{i=1}^{H_j} \prod_{k=1}^{H_{j+1}} \mathcal{N}(w_{ijk}^{(t)} | m_{ijk}^{(t)}, v_{ijk}^{(t)}). \\ &= q_p(W) q_p(\gamma_y) q_p(\gamma_w). \end{aligned}$$

5.2.5.3 初期化と事前分布因子の導入

“一様”^{“sui”}の意味。

$q_p(W, \gamma_y, \gamma_w)$ が“無情報”にたどるようには、パラメータを設定：

$$m_{ijk}^{(t)} = 0, \quad v_{ijk}^{(t)} = \infty$$

$$\alpha_{\gamma_y} = 1, \quad \beta_{\gamma_y} = 0$$

$$\alpha_{\gamma_w} = 1, \quad \beta_{\gamma_w} = 0$$

この値

すぐに更新される。

あまり気にしないでいいかも。

c.f.) 無情報事前分布 (noninformative prior), 非正則事前分布 (improper prior)

- やると：逐次学習

$$q_{i+1}(\theta) \approx \frac{1}{z_{i+1}} f_{i+1}(\theta) q_i(\theta), \quad \theta = \{W, \gamma_y, \gamma_w\}.$$

$f_{i+1}(\theta)$ として

$$p(W, \gamma_y, \gamma_w | Y, X)$$

$$\propto p(Y | X, W, \gamma_y) p(W | \gamma_w) p(\gamma_y) p(\gamma_w)$$

$$= \left(\prod_{n=1}^N \mathcal{N}(y_n | f(x_n; W), \gamma_y^{-1}) \right) \left(\prod_{j=1}^L \prod_{i=1}^{H_j} \prod_{k=1}^{H_{j+1}} \mathcal{N}(w_{ijk}^{(t)} | D, \gamma_w^{-1}) \right) p(\gamma_y) p(\gamma_w)$$

尤度因子

事前分布因子

の各因子を次々と設定することで $q(\theta)$ を更新していく。

- まずは事前分布因子の情報を追加していく:

f として $p(\gamma_w)$, $p(\gamma_y)$, $\mathcal{N}(w_{i,j}^{(t)} | 0, \gamma_w^{-1})$ を設定して,

$q(\gamma_y)$, $q(\gamma_w)$, $q(W)$ のパラメータを更新.

- 次いで、尤度因子の情報を追加していく:

f として $\mathcal{N}(y_n | f(x_n; W), \gamma_y^{-1})$ を設定して

$q(\gamma_y)$, $q(W)$ のパラメータを更新.

1. $p(\gamma_y)p(\gamma_w)$ の導入.

$q(\gamma_y)q(\gamma_w)$ の形は以下のようだ. q のパラメータを導入

$$\alpha_{\gamma_y} \leftarrow \alpha_{\gamma_y, 0}, \beta_{\gamma_y} \leftarrow \beta_{\gamma_y, 0}, \alpha_{\gamma_w} \leftarrow \alpha_{\gamma_w, 0}, \beta_{\gamma_w} \leftarrow \beta_{\gamma_w, 0}$$

と更新すればよい.

2. $\mathcal{N}(w_{i,j}^{(t)} | 0, \gamma_w^{-1})$ の導入.

$$q_{\text{new}}(w_{i,j}^{(t)}) q_{\text{new}}(\gamma_w)$$

$$\approx \frac{1}{Z_0} \mathcal{N}(w_{i,j}^{(t)} | 0, \gamma_w^{-1}) q(w_{i,j}^{(t)}) q(\gamma_w)$$

$$= \frac{1}{Z_0} \mathcal{N}(w_{i,j}^{(t)} | 0, \gamma_w^{-1}) \mathcal{N}(w_{i,j}^{(t)} | m_{i,j}^{(t)}, v_{i,j}^{(t)}) \text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w}),$$

$$Z_0 = Z(\alpha_{\gamma_w}, \beta_{\gamma_w})$$

$$= \int \mathcal{N}(w_{i,j}^{(t)} | 0, \gamma_w^{-1}) \mathcal{N}(w_{i,j}^{(t)} | m_{i,j}^{(t)}, v_{i,j}^{(t)}) \text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w}) dw_{i,j}^{(t)} d\gamma_w$$

• $m_{i,j}^{(t)}, V_{i,j}^{(t)}$ の更新. §4.2, 4.3 の結果から.

$$m_{i,j}^{(t)} \leftarrow m_{i,j}^{(t)} + V_{i,j}^{(t)} \frac{\partial}{\partial m_{i,j}^{(t)}} \log Z_0$$

$$V_{i,j}^{(t)} \leftarrow V_{i,j}^{(t)} - V_{i,j}^{(t)2} \left(\left(\frac{\partial}{\partial m_{i,j}^{(t)}} \log Z_0 \right)^2 - 2 \frac{\partial}{\partial V_{i,j}^{(t)}} (\log Z_0) \right).$$

• $\alpha_{\gamma_w}, \beta_{\gamma_w}$ の更新. §4.2, 4.4 の結果から.

$$\alpha_{\gamma_w} \leftarrow \left(Z_0 Z_2 Z_1^{-1} \frac{\alpha_{\gamma_w} + 1}{\beta_{\gamma_w}} - 1 \right)^{-1} \quad Z_1 = Z(\alpha_{\gamma_w} + 1, \beta_{\gamma_w}),$$

$$\beta_{\gamma_w} \leftarrow \left(Z_2 Z_1^{-1} \frac{\alpha_{\gamma_w} + 1}{\beta_{\gamma_w}} - Z_1 Z_0^{-1} \frac{\alpha_{\gamma_w}}{\beta_{\gamma_w}} \right)^{-1} \quad Z_2 = Z(\alpha_{\gamma_w} + 2, \beta_{\gamma_w}).$$

$Z(\alpha_{\gamma_w}, \beta_{\gamma_w})$ を求めめる必要があるが、

厳密解は得られないので近似計算.

$Z(\alpha_{\gamma_w}, \beta_{\gamma_w})$

$$= \int N(w_{i,j}^{(t)} | 0, \gamma_w^{-1}) N(w_{i,j}^{(t)} | m_{i,j}^{(t)}, V_{i,j}^{(t)}) \text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w}) dw_{i,j}^{(t)} d\gamma_w$$

$$= \int \left(\int N(w_{i,j}^{(t)} | 0, \gamma_w^{-1}) \text{Gam}(\gamma_w | \alpha_{\gamma_w}, \beta_{\gamma_w}) d\gamma_w \right) N(w_{i,j}^{(t)} | m_{i,j}^{(t)}, V_{i,j}^{(t)}) dw_{i,j}^{(t)}$$

$$= \int St(w_{i,j}^{(t)} | 0, \frac{\alpha_{\gamma_w}}{\beta_{\gamma_w}}, 2\alpha_{\gamma_w}) N(w_{i,j}^{(t)} | m_{i,j}^{(t)}, V_{i,j}^{(t)}) dw_{i,j}^{(t)} \quad \downarrow \text{§3.2, 4.4 の予測分布}$$

$$\approx \int N(w_{i,j}^{(t)} | 0, \frac{\beta_{\gamma_w}}{\alpha_{\gamma_w} - 1}) N(w_{i,j}^{(t)} | m_{i,j}^{(t)}, V_{i,j}^{(t)}) dw_{i,j}^{(t)} \quad \downarrow \text{Student's t 分布と平均と分散の等しい Gaussian 分布で近似}$$

$\approx Z''$,

$$\int N(w | 0, \lambda_1^{-1}) N(w | m, \lambda_2^{-1}) dw$$

$$= \int \frac{\sqrt{\lambda_1}}{\sqrt{2\pi}} \exp\left(-\frac{\lambda_1}{2} w^2\right) \frac{\sqrt{\lambda_2}}{\sqrt{2\pi}} \exp\left(-\frac{\lambda_2}{2} (w-m)^2\right) dw$$

$$= \frac{\sqrt{\lambda_1}}{\sqrt{2\pi}} \frac{\sqrt{\lambda_2}}{\sqrt{2\pi}} \int \exp\left(-\frac{1}{2} ((\lambda_1 + \lambda_2)w^2 - 2\lambda_2 m w + \lambda_2 m^2)\right) dw \quad \text{平方完成}$$

$$= \frac{\sqrt{\lambda_1}}{\sqrt{2\pi}} \frac{\sqrt{\lambda_2}}{\sqrt{2\pi}} \int \exp\left(-\frac{\lambda_1 + \lambda_2}{2} \left(w - \frac{\lambda_2}{\lambda_1 + \lambda_2} m\right)^2\right) \exp\left(-\frac{1}{2} \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2} m^2\right) dw$$

$$\begin{aligned}
&= \frac{\sqrt{\lambda_1}}{\sqrt{2\pi}} \frac{\sqrt{\lambda_2}}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2} m^2\right) \frac{\exp\left(-\frac{\lambda_1 + \lambda_2}{2} \left(w - \frac{\lambda_2}{\lambda_1 + \lambda_2} m\right)^2\right)}{\sqrt{\frac{2\pi}{\lambda_1 + \lambda_2}}} dw \\
&= \frac{1}{\sqrt{2\pi}} \sqrt{\frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2}} \exp\left(-\frac{1}{2} \frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2} m^2\right) \\
&= \mathcal{N}(m | 0, \left(\frac{\lambda_1 \lambda_2}{\lambda_1 + \lambda_2}\right)^{-1})
\end{aligned}$$

7.2.4.2.

$$\mathcal{Z}(\alpha_{\gamma_w}, \beta_{\gamma_w}) \approx \mathcal{N}(m_{i,j}^{(0)} | 0, \frac{\beta_{\gamma_w}}{\alpha_{\gamma_w} - 1} + V_{i,j}^{(0)})$$

$$\frac{\partial}{\partial m_{i,j}^{(0)}} \log \mathcal{Z}_0, \frac{\partial}{\partial V_{i,j}^{(0)}} \log \mathcal{Z}_0, \mathcal{Z}_1, \mathcal{Z}_2 \text{ はこれで計算可能}.$$

7.2.5.4 精度因子の導入.

$$3. \mathcal{N}(y_n | f(\alpha_n; \mathcal{W}), \gamma_y^{-1}) の導入.$$

$$q_{\text{new}}(\mathcal{W}) q_{\text{new}}(\gamma_y)$$

$$\approx \frac{1}{\mathcal{Z}} \mathcal{N}(y_n | f(\alpha_n; \mathcal{W}), \gamma_y^{-1}) q(\mathcal{W}) q(\gamma_y)$$

$$= \frac{1}{\mathcal{Z}} \mathcal{N}(y_n | f(\alpha_n; \mathcal{W}), \gamma_y^{-1}) q(\mathcal{W}) \text{Gam}(\gamma_y | \alpha_{\gamma_y}, \beta_{\gamma_y}).$$

$$= \frac{1}{\mathcal{Z}} \mathcal{N}(y_n | f(\alpha_n; \mathcal{W}), \gamma_y^{-1}) \left(\prod_{l=1}^L \prod_{i=1}^{H_l} \prod_{j=1}^{H_{l+1}} q(m_{i,j}^{(0)}) \right) \text{Gam}(\gamma_y | \alpha_{\gamma_y}, \beta_{\gamma_y}).$$

$$\mathcal{Z} = \mathcal{Z}(\alpha_{\gamma_y}, \beta_{\gamma_y})$$

$$= \int \mathcal{N}(y_n | f(\alpha_n; \mathcal{W}), \gamma_y^{-1}) q(\mathcal{W}) \text{Gam}(\gamma_y | \alpha_{\gamma_y}, \beta_{\gamma_y}) d\mathcal{W} d\gamma_y$$

• $m_{i,j}^{(0)}, V_{i,j}^{(0)}$ の更新. §7.2.4.3 の結果参考.

$$m_{i,j}^{(0)} \leftarrow m_{i,j}^{(0)} + V_{i,j}^{(0)} \frac{\partial}{\partial m_{i,j}^{(0)}} \log \mathcal{Z}$$

$$V_{i,j}^{(0)} \leftarrow V_{i,j}^{(0)} - V_{i,j}^{(0)2} \left(\left(\frac{\partial}{\partial m_{i,j}^{(0)}} \log \mathcal{Z} \right)^2 - 2 \frac{\partial}{\partial V_{i,j}^{(0)}} \log \mathcal{Z} \right).$$

- $\alpha_{\gamma_y}, \beta_{\gamma_y}$ の更新. §4.2.4.4 の結果より,

$$\alpha_{\gamma_y} \leftarrow \left(\mathcal{Z}_2 \mathcal{Z}_1^{-1} \frac{\alpha_{\gamma_y} + 1}{\alpha_{\gamma_y}} - 1 \right)^{-1} \quad \mathcal{Z}_1 = \mathcal{Z}(\alpha_{\gamma_y} + 1, \beta_{\gamma_y}),$$

$$\beta_{\gamma_y} \leftarrow \left(\mathcal{Z}_2 \mathcal{Z}_1^{-1} \frac{\alpha_{\gamma_y} + 1}{\beta_{\gamma_y}} - \mathcal{Z}_1 \mathcal{Z}_1^{-1} \frac{\alpha_{\gamma_y}}{\beta_{\gamma_y}} \right)^{-1} \quad \mathcal{Z}_2 = \mathcal{Z}(\alpha_{\gamma_y} + 2, \beta_{\gamma_y}).$$

$\rightarrow \mathcal{Z} = \mathcal{Z}(\alpha_{\gamma_y}, \beta_{\gamma_y})$ が求まればパラメータの更新が可能.

$\mathcal{W} \sim q(\mathcal{W})$ のとき, $\mathcal{Z}^{(L)} = f(x_n; \mathcal{W})$ の分布は複雑になるので.

$\mathcal{Z}^{(L)} \sim \mathcal{N}(\mathcal{Z}^{(L)} | m_{\mathcal{Z}^{(L)}}, \sigma_{\mathcal{Z}^{(L)}}^2)$ で近似してしまおう.

つまり, $q(\mathcal{W}) d\mathcal{W} = p(\mathcal{Z}^{(L)}) d\mathcal{Z}^{(L)} \approx \mathcal{N}(\mathcal{Z}^{(L)} | m_{\mathcal{Z}^{(L)}}, \sigma_{\mathcal{Z}^{(L)}}^2) d\mathcal{Z}^{(L)}$ です.

Remark 式 $q(\mathcal{W}) d\mathcal{W} = p(\mathcal{Z}^{(L)}) d\mathcal{Z}^{(L)}$ は、変数交換の公式そのものではありません.

$\left(\because \text{一般には } \mathcal{W} \text{ と } \mathcal{Z}^{(L)} \text{ の次元が違う}, \mathcal{Z}^{(L)} = f(x_n; \mathcal{W}) \right)$
 は全単射にならない