

Ch.4 混合モデルと近似推論.

4.1 混合モデルと事後分布の推論

- 現実世界の複雑なデータ生成過程を記述するのに、単純なモデルでは表現しきれない。
→ **混合モデル**：複数のモデルを組みあわせて使う。

4.1.1 混合モデルを使う理由

- データのクラスタやトレンド等複数個あるとき、一つのモデルでは表現できない。
- 他の確率モデルと組みあわせやすい。

4.1.2 混合モデルのデータ生成過程

Kクラスタからなるデータ $X = \{x_1, \dots, x_N\}$ の生成過程と、次のモデル（生成モデル）で記述してみる：

1. 各クラスタの混合比率

$$\pi_C = \begin{pmatrix} \pi_1 \\ \vdots \\ \pi_K \end{pmatrix} \quad \pi_k \in (0, 1), \quad \sum_{k=1}^K \pi_k = 1$$

から事前分布 $p(\pi)$ から生成。

2. 各クラスタ $k = 1, \dots, K$ に対する観測モデル $p(x|{\theta}_k)$ の

パラメータ θ_k は、事前分布 $p(\theta_k)$ から生成。

3. 各 $n = 1, \dots, N$ に対して、 x_n に対するクラスタの割り当て

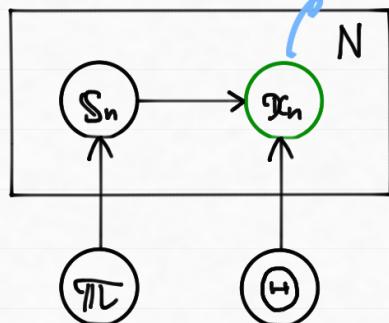
s_n (潜在変数) が 比率 π を利用して $p(s_n|\pi)$ から生成。

この変数は直接観測することができない。

4. 各 $n = 1, \dots, N$ に対して、 s_n で選ばれた k 番目の

モデル $p(x|{\theta}_k)$ から x_n が生成。

・ グラフィカルモデル:



$$\Theta := \{\theta_1, \dots, \theta_K\}.$$

* 上の生成モデルをより具体的に書いてみる。

・ 4. について。

観測モデル $p(x|{\theta}_k)$ を Gauss 分布にしてみる:

$$x_n \sim p(x_n|{\theta}_k) := \mathcal{N}(x_n | \mu_k, \Sigma_k) \quad (k = 1, \dots, K).$$

$$(\theta_k := \{\mu_k, \Sigma_k\}).$$

• 3. はじめ.

$s_n := 1 \text{ if } K \text{ 表現を便} \rightarrow \text{これはカテゴリ分布からサンプリングでOK}$

$$s_n = \begin{pmatrix} s_{n,1} \\ \vdots \\ s_{n,K} \end{pmatrix} \sim p(s_n | \pi) := \text{Cat}(s_n | \pi)$$

(π : 混合比率パラメータ)

→ 3と4をあわせて、

$$x_n \sim p(x_n | s_n, \Theta) = \prod_{k=1}^K p(x_n | \Theta_k)^{s_{n,k}} \quad (\Theta = \{\Theta_1, \dots, \Theta_K\})$$

と書ける。

• 2. はじめ.

Θ_k の事前分布 $p(\Theta_k)$ を定める: $\Theta_k \sim p(\Theta_k)$.

4. で設定したモデル $p(x_n | \Theta_k)$ の共役事前分布となるのが良い。

ここで、Gauss/分布を設定しているので、Gauss-Wishart/分布:

$$p(\Theta_k) = \text{NW}(\mu_k, \Sigma_k | m, \beta, \nu, W).$$

• 1. はじめ.

π の事前分布 $p(\pi)$ を定める: $\pi \sim p(\pi)$.

π : カテゴリ分布のパラメータなので、この天役事前分布である

K次元 Dirichlet 分布に設定。

$$p(\pi) := \text{Dir}(\pi | \alpha) \quad (\alpha: \text{ハイパーパラメータ})$$

- 以上より, $S = \{s_1, \dots, s_N\}$ として, モデルの全体像は次のとおり:

$$\begin{aligned} p(X, S, \Theta, \pi) &= p(X|S, \Theta, \pi)p(S|\Theta, \pi)p(\Theta|\pi)p(\pi) \\ &= p(X|S, \Theta)p(S|\pi)p(\Theta)p(\pi) \quad \downarrow \text{独立性} \\ &= \left(\prod_{n=1}^N p(x_n|s_n, \Theta) \right) \left(\prod_{k=1}^K p(\Theta_k) \right) p(\pi). \end{aligned}$$

4.1.3 混合モデルの事後分布.

- X : given.

S, Θ, π の事後分布

$$p(S, \Theta, \pi | X) = \frac{p(X, S, \Theta, \pi)}{p(X)},$$

あるいは、データ X の所属クラスタ S の推定を行うために

$$p(S | X) = \iint p(S, \Theta, \pi | X) d\Theta d\pi$$

を計算したい。

→ 混合モデルで、これらの計算は効率的にできません！

∴ 事後分布は ς, θ, π カの複雑に絡みあつた分布で、

$p(x)$ の計算が困難：

$$p(x) = \sum_{\varsigma} \iint p(x, \varsigma, \theta, \pi) d\theta d\pi$$

周辺化

$$= \sum_{\varsigma} p(x, \varsigma).$$

\sum_{ς} は、 $\varsigma = \{\varsigma_1, \dots, \varsigma_N\}$ についての組合せ全てについての和。

ς_k のパターンは K 通り。 N こあつて ς の組合せは K^N 通り。

機械学者で用ひるデータは N 大であることが多いので

この計算は現実的な時間で終わらない。

§4.2 確率分布の近似手法.

- 近似推論 (approximate inference) :

直接 $p(\mathbf{z})$ の計算をするのは複雑で、簡単な計算で済ませる枠組み.

4.2.1 Gibbsサンプリング.

$\mathbf{z} = (z_1, \dots, z_M)^T$. $p(\mathbf{z})$ について、期待値計算などを行いたい.

→ \mathbf{z} の実現値を複数回サンプルして計算する:

$$\mathbf{z}^{(i)} \sim p(\mathbf{z}) \quad (i = 1, 2, \dots)$$

- 分布 $p(\mathbf{z})$ が複雑だと、全変数を同時にサンプルするのは困難.

→ Gibbsサンプリング (MCMCの手法の一種)

i個目の変数 $z_i^{(i)}$ の各成分 $z_m^{(i)}$ を次のように一々サンプリング:

```

for i = 1, 2, ..., N_max do
     $z_1^{(i)} \sim p(z_1 | z_2^{(i-1)}, z_3^{(i-1)}, \dots, z_M^{(i-1)})$ ;
     $z_2^{(i)} \sim p(z_2 | z_1^{(i)}, z_3^{(i-1)}, \dots, z_M^{(i-1)})$ ;
    ...
     $z_M^{(i)} \sim p(z_M | z_1^{(i)}, z_2^{(i)}, \dots, z_{M-1}^{(i)})$ 
end for.

```

$z_2^{(0)}, \dots, z_M^{(0)}$ についてはランダムに与えておく。

 $z_1^{(i)}$ ではない!

- Gibbsサンプリングのアイデア：

\mathbf{z}_m をサンプルするために、既にサンプルされた値で「分布を条件付けて、よりサンプルやすい分布を得る。

- Gibbsサンプリング：よりサンプリングされた \mathbf{z}_m は、サンプル数が十分なら真の事後分布からサンプルされたものとみなせる（これが知られてる）。
- 問題点：推論に必要なサンプル数が明確でない。

→サンプル点かと並べて「うよく真の分布を表しているのかを知ることはできな」（可視化や一般にてきないため）。

- * Gibbsサンプリングの変種。

- ブロックギブスサンプリング

$\mathbf{z} = (\mathbf{z}_1^T, \dots, \mathbf{z}_K^T)^T$ とブロックに分かれているとする。

各 \mathbf{z}_k の全成分は同時にサンプリングでさるとする。

このとき、 i 個目の変数 $\mathbf{z}^{(i)}$ の各ブロック $\mathbf{z}_k^{(i)}$ は、

通常の Gibbsサンプリングのように、一つずつサンプリングする。

擬似コードで表すと、次のとおり：

```

for i = 1, 2, ..., Nmax do
     $\mathbf{z}_1^{(i)} \sim p(\mathbf{z}_1 | \mathbf{z}_2^{(i-1)}, \mathbf{z}_3^{(i-1)}, \dots, \mathbf{z}_K^{(i-1)}) ;$ 
     $\mathbf{z}_2^{(i)} \sim p(\mathbf{z}_2 | \mathbf{z}_1^{(i)}, \mathbf{z}_3^{(i-1)}, \dots, \mathbf{z}_K^{(i-1)}) ;$ 
    :
     $\mathbf{z}_K^{(i)} \sim p(\mathbf{z}_K | \mathbf{z}_1^{(i)}, \mathbf{z}_2^{(i)}, \dots, \mathbf{z}_{K-1}^{(i)})$ 
end for.

```

✓ ブロックごとの"複数の同時サンプリング"

→ より真の事後分布に近いサンプルが得られる。

△ サンプリングに使う各条件付き分布が、計算コスト的に十分簡単にサンプリングできる必要がある。

• 崩壊型 Gibbs サンプリング

$\mathbf{z} = (\mathbf{z}_1^\top, \mathbf{z}_2^\top)^\top$ として、同辺化によりモデルから \mathbf{z}_2 を減ぼす：

$$p(\mathbf{z}_1) = \int p(\mathbf{z}) d\mathbf{z}_2. \quad - (*)$$

$p(\mathbf{z}_1)$ について、通常の Gibbs サンプリングを行う。

✓ サンプリングする複数ではなく、高速にサンプリングができる。

△ (*)の計算が解析的にできなければならぬ。

△ 減ぼした \mathbf{z}_2 のサンプリングが容易に行える必要がある。

4.2.2 变分推論

- 变分推論 (variational inference) :

最適化問題を解いて、未知の確率分布の近似的な表現を得る。

- $P(\mathbf{z})$: 近似表現を得たい複雑な分布。

$\rightarrow P \in$ より簡単な分布 $q_p(\mathbf{z})$ で近似する。
「分布 q_p が p と
似てない限りは」

$$\rightarrow q_{\text{opt}}(\mathbf{z}) := \underset{q}{\operatorname{argmin}} \text{KL}[q(\mathbf{z}) \| P(\mathbf{z})] \quad -(*)$$

となるように $q_{\text{opt}}(\mathbf{z})$ を選ぶ"といふ？

- (*) を制約なしで解くと、 $q_{\text{opt}} = P$ となり意味がない。

$\rightarrow q_p$ の表現能力を限定し、このもとで最適化とする。

- 平均場近似 (mean-field approximation) に基いて变分推論。

q_p に独立性を仮定する、i.e., 次式で P を近似：

$$P(\mathbf{z}) \approx \prod_{m=1}^M q_{p_m}(z_m)$$

\rightarrow 各 q_{p_m} で、KL divergence を小さくするように
一々一々更新していく。

- q_{p_m} ($m = 2, \dots, M$) : given とする。このとき、最適な q_{p_1} は、

$$q_{p_1}^*(z_1) := \underset{q_{p_1}}{\operatorname{argmin}} \text{KL}[q_{p_1}(z_1) \prod_{m \neq 1} q_{p_m}(z_m) \| P(\mathbf{z})]$$

で求まる。KL divergence を計算してみる。

$$\mathbb{E}_{q_1, \dots, q_M}[\cdot] =: \mathbb{E}_{1, \dots, M}[\cdot] \text{ などと書く。}$$

$$\begin{aligned}
 & \text{KL}[q_{f_1}(\mathbf{z}_1) \prod_{m \neq 1} q_{f_m}(\mathbf{z}_m) \| p(\mathbf{z})] \\
 &= -\mathbb{E}_{1, \dots, M} \left[\log \frac{p(\mathbf{z})}{q_{f_1}(\mathbf{z}_1) \prod_{m \neq 1} q_{f_m}(\mathbf{z}_m)} \right] \quad \downarrow \text{期待値を分解。} \\
 &= -\mathbb{E}_1 \left[\mathbb{E}_{2, \dots, M} \left[\log \frac{p(\mathbf{z})}{q_{f_1}(\mathbf{z}_1) \prod_{m \neq 1} q_{f_m}(\mathbf{z}_m)} \right] \right] \quad \downarrow \text{期待値を計算} \\
 &= -\mathbb{E}_1 \left[\mathbb{E}_{2, \dots, M} \left[\log p(\mathbf{z}) - \log q_{f_1}(\mathbf{z}_1) - \underbrace{\sum_{m \neq 1} \log q_{f_m}(\mathbf{z}_m)}_{\text{const.}} \right] \right] \quad \downarrow \text{期待値の線形性} \\
 &= -\mathbb{E}_1 \left[\mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})] - \underbrace{\mathbb{E}_{2, \dots, M} [\log q_{f_1}(\mathbf{z}_1)]}_{q_1 \approx q_2 \sim q_M \text{ は仮定}} + \text{const.} \right. \\
 &= -\mathbb{E}_1 \left[\mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})] - \log q_{f_1}(\mathbf{z}_1) + \text{const.} \right. \quad \downarrow \log \circ \exp = \text{id.} \\
 &= -\mathbb{E}_1 \left[\log (\exp(\mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})])) - \log q_{f_1}(\mathbf{z}_1) \right] + \text{const.}
 \end{aligned}$$

$$= -\mathbb{E}_1 \left[\log \frac{\exp(\mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})])}{q_{f_1}(\mathbf{z}_1)} \right] + \text{const.}$$

$$= \text{KL}[q_{f_1}(\mathbf{z}_1) \| \exp(\mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})])] + \text{const.}$$

これは $q_{f_1}(\mathbf{z}_1) = \exp(\mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})])$ のとき最小。

$\therefore q_{f_1}^*(\mathbf{z}_1)$ は次式を満たす:

$$\log q_{f_1}^*(\mathbf{z}_1) = \mathbb{E}_{2, \dots, M} [\log p(\mathbf{z})] + \text{const.}$$

要するに?

・ 残りの分布 $q_{p_m}^*(z_m)$ ($m = 2, \dots, M$)についても同様.

$$\mathbf{z}_{\setminus m} := (z_1, \dots, z_{m-1}, z_{m+1}, \dots, z_n)^T \quad (m = 1, \dots, M) \text{ と } \text{LT},$$

$\mathbb{E}_{q_p(z_m)} [\cdot] =: \mathbb{E}_m [\cdot]$ と書くことにする.

後方推論のアルゴリズムは次の通り:

```

for m = 2, ..., M do
    initialize  $q_{p_m}(z_m)$ 
end for;

for i = 1, ...,  $N_{\max}$  do
    for m = 1, ..., M do
         $\log q_{p_m}(z_m) := \mathbb{E}_m [\log p(z)] + \text{const.}$ 
    end for
end for.

```

・ 繰り返しの終了条件としては、上記のように N_{\max} を設定する

以外にも、計算時間と制限する、ELBO (evidence lower bound)

などの評価値の収束をもって終了するなどの方法がある。

- ELBOについては後述.

未観測変数



- 観測データ \mathcal{D} が与えられたときの、確率モデル $p(\mathcal{D}, \mathbf{z})$ の事後分布 $p(\mathbf{z}|\mathcal{D})$ の近似は、先の計算で $p(\mathbf{z})$ の部分を $p(\mathbf{z}|\mathcal{D})$ とすればよく、

$$\begin{aligned}\log q_m(\mathbf{z}_m) &= \mathbb{E}_{\mathbf{z}_m} [\log p(\mathbf{z}|\mathcal{D})] + \text{const.} \quad \downarrow p(\mathcal{D}) \text{ は const. に} \\ &= \mathbb{E}_{\mathbf{z}_m} [\log p(\mathcal{D}, \mathbf{z})] + \text{const.}\end{aligned}$$

✓ Gibbsサンプリングより高速。

△ 強い相関をもつ分布でうまく近似できない。

構造化変分推論 (structured variational inference)

$$p(\mathbf{z}) \approx \prod_{k=1}^K q_k(z_k)$$

のように、大きなまとまりで近似する。

✓ 変数間の相関をとらえることができる、よい近似になる。

△ メモリコスト、計算コストの増加。

c. ELBOについて。

- 変分推論：周辺尤度の下限の最大化アルゴリズムとも考えることができる。

- 観測データ \mathcal{D} , 未観測変数 $\mathbf{z} = (z_1, \dots, z_n)^T$ について,
確率モデル $p(\mathcal{D}, \mathbf{z})$ を考え, \mathbf{z} についての分布 $q(\mathbf{z})$ を
仮定する.

Thm. (Jensen の不等式)

X : r.v. $X \sim p(x)$, $f: \mathbb{R} \rightarrow \mathbb{R}$: 凸函数.

このとき, $f(\mathbb{E}_p[X]) \leq \mathbb{E}_p[f(X)]$. □

pf. f : 凸函数より. $\forall x_0 \in \mathbb{R}$,

$$f(x) \geq f(x_0) + f'(x_0)(x - x_0), \quad \forall x \in \mathbb{R}. \quad \text{「接線よりも上にいく」}$$

$x \in X$ として期待値をとると,

$$\mathbb{E}_p[f(X)] \geq f(x_0) + f'(x_0)(\mathbb{E}_p[X] - x_0).$$

$x_0 = \mathbb{E}_p[X]$ とすると

$$f(\mathbb{E}_p[X]) \leq \mathbb{E}_p[f(X)]. \quad \blacksquare$$

[Claim] $-\log$ は凸函数.

pf. 分かり. □

Cor. X : r.v. $X \sim p(x)$,

$$\text{このとき, } \log \mathbb{E}_p[X] \geq \mathbb{E}_p[\log X]. \quad \blacksquare$$

この不等式を用いると、モデルの周辺尤度 $p(\mathcal{D})$ の対数について、

下限を計算できる：

$$\begin{aligned}
 & \log p(\mathcal{D}) \\
 &= \log \left(\int p(\mathcal{D}, \mathbf{z}) d\mathbf{z} \right) \quad \downarrow \text{周辺化} \\
 &= \log \left(\int \frac{p(\mathcal{D}, \mathbf{z})}{q_{\mathbf{f}}(\mathbf{z})} q_{\mathbf{f}}(\mathbf{z}) d\mathbf{z} \right) \quad \downarrow \text{期待値, 定義} \\
 &= \log \mathbb{E}_{q_{\mathbf{f}}} \left[\frac{p(\mathcal{D}, \mathbf{z})}{q_{\mathbf{f}}(\mathbf{z})} \right] \quad \downarrow \text{先の Cor.} \\
 &\geq \mathbb{E}_{q_{\mathbf{f}}} \left[\log \frac{p(\mathcal{D}, \mathbf{z})}{q_{\mathbf{f}}(\mathbf{z})} \right] \quad \downarrow \text{期待値, 定義} \\
 &= \int q_{\mathbf{f}}(\mathbf{z}) \log \frac{p(\mathcal{D}, \mathbf{z})}{q_{\mathbf{f}}(\mathbf{z})} d\mathbf{z} \\
 &=: \mathcal{L}[q_{\mathbf{f}}(\mathbf{z})]
 \end{aligned}$$

Def. (ELBO)

対数周辺尤度の下限 $\mathcal{L}[q_{\mathbf{f}}(\mathbf{z})]$ を分布 $q_{\mathbf{f}}(\mathbf{z})$ に対する

ELBO という。

→ $\mathcal{L}[q_{\mathbf{f}}(\mathbf{z})]$ をなるべく大きくする $q_{\mathbf{f}}(\mathbf{z})$ を求めることで、 $\log p(\mathcal{D})$ を近似的に計算できる。

$\log p(\mathcal{D})$ が大きくなるほど q_f を選んでいるわけではなし。
 $\mathcal{L}[q_f(z)]$ が $\log p(\mathcal{D})$ と一番よく近似する q_f を選んでいる。
 $\rightarrow q_f^*(z) := \operatorname{argmax}_q \mathcal{L}[q_f(z)]$ により q_f を選択する。

Prop. $\log p(\mathcal{D}) - \mathcal{L}[q_f(z)] = \text{KL}[q_f(z) \| p(z|\mathcal{D})]$. \square

pf. $\log p(\mathcal{D}) - \mathcal{L}[q_f(z)]$

\downarrow by def.

$$= \log p(\mathcal{D}) - \int q_f(z) \log \frac{p(\mathcal{D}, z)}{q_f(z)} dz$$

$\downarrow p(\mathcal{D}, z) = p(z|\mathcal{D})p(\mathcal{D})$

$$= \log p(\mathcal{D}) - \int q_f(z) \log \frac{p(z|\mathcal{D})p(\mathcal{D})}{q_f(z)} dz$$

$\downarrow \log a + b$

$$= \log p(\mathcal{D}) - \int q_f(z) \left(\log \frac{p(z|\mathcal{D})}{q_f(z)} + \log p(\mathcal{D}) \right) dz$$

$$= \cancel{\log p(\mathcal{D})} - \int q_f(z) \log \frac{p(z|\mathcal{D})}{q_f(z)} dz - \cancel{\log p(\mathcal{D})} \int q_f(z) dz$$

$= \text{KL}[q_f(z) \| p(z|\mathcal{D})] = 1$

$$= \text{KL}[q_f(z) \| p(z|\mathcal{D})].$$

\blacksquare

・ $\log p(\mathcal{D})$ は \mathcal{D} : given つまり一定値。

以上より、 $\mathcal{L}[q_f(z)]$ が最大となる q_f を選ぶこと、

$\text{KL}[q_f(z) \| p(z|\mathcal{D})]$ が最小となる q_f を選ぶことは等価。

§4.3 Poisson混合モデルにおける推論.

4.3.1 Poisson混合モデル

- 多峰性の離散非負データの字習に利用できる.
- $\lambda = \{\lambda_1, \dots, \lambda_K\}$: パラメータ.

クラスター k に対する観測モデル: $p(x_n | \lambda_k) := \text{Poi}(x_n | \lambda_k)$.

→ 混合分布における条件付き分布は.

$$p(x_n | s_n, \lambda) = \prod_{k=1}^K \text{Poi}(x_n | \lambda_k)^{s_{n,k}}$$

s_n によって, K つの Poisson 分布の一つが指定される.

- λ に対して, 事前分布を設定する.

Poisson 分布の共役事前分布 → ガンマ分布.

$$p(\lambda_k) := \text{Gam}(\lambda_k | a_k, b_k), \quad a_k, b_k: \text{パラメータ}.$$

クラスターごとに
 a_k, b_k とパラメータと
同じでも良い.

- s_n に対する事前分布は, $p(s_n | \pi) := \text{Cat}(s_n | \pi)$,

π に対する事前分布は, $p(\pi) := \text{Dir}(\pi | \alpha)$

$$(\alpha: \text{パラメータ})$$

と設定することにする.

Remark モデルを構築した後は、データの表現能力や挙動について、
思い違いやミスがないかと確認するため、いくつかの 1111^0-11^0 ラメータ
を使ってサンプルを得てみて、視覚的に確認してみるとよい。

問題によれば、事前知識を与えることで"さる"。

4.3.2 Gibbsサンプリング

- $\mathcal{X} = \{\alpha_1, \dots, \alpha_N\}$: given. このとき、条件付き分布は、
 $p(S, \pi, \lambda | \mathcal{X})$. この分布から S, π, λ をサンプルする
 アルゴリズムを、Gibbsサンプリングにより導出。
- 混合分布では、潜在変数と分布のパラメータを分けてサンプリング
 すると、十分に簡単な分布が得られる(らしい)。
 → 次のようにサンプリングすることにする：

$$S^{(i)} \sim p(S | \pi^{(i-1)}, \lambda^{(i-1)}, \mathcal{X}) \quad - (1)$$

$$\pi^{(i)}, \lambda^{(i)} \sim p(\pi, \lambda | S^{(i)}, \mathcal{X}) \quad - (2)$$

- (1)について、 $S^{(i)} = \{S_1^{(i)}, \dots, S_N^{(i)}\}$ をサンプルするための
 条件付き分布 $p(S | \underline{\pi^{(i-1)}, \lambda^{(i-1)}}, \mathcal{X})$ を求める。
given として扱うのがポイント。

$$p(S | \pi^{(i-1)}, \lambda^{(i-1)}, \mathcal{X})$$

$$\propto p(S, \pi^{(i-1)}, \lambda^{(i-1)}, \mathcal{X}) \quad \downarrow \text{乗法則}$$

$$= p(\mathcal{X} | S, \pi^{(i-1)}, \lambda^{(i-1)}) p(S | \pi^{(i-1)}, \lambda^{(i-1)}) \underbrace{p(\pi^{(i-1)}, \lambda^{(i-1)})}_{\text{const.}}$$

$$\propto p(\mathcal{X} | S, \lambda^{(i-1)}) p(S | \pi^{(i-1)}) \quad \downarrow \text{独立性}$$

$$= \left(\prod_{n=1}^N p(x_n | S, \lambda^{(i-1)}) \right) \left(\prod_{n=1}^N p(s_n | \pi^{(i-1)}) \right)$$

$$= \left(\prod_{n=1}^N p(x_n | s_n, \lambda^{(i-1)}) \right) \left(\prod_{n=1}^N p(s_n | \pi^{(i-1)}) \right)$$

$$= \prod_{n=1}^N p(x_n | s_n, \lambda^{(i-1)}) p(s_n | \pi^{(i-1)})$$

→ 各 $s_n^{(i)}$ が 独立にサンプリングでできる (条件付き独立性).

- $s_n^{(i)}$ をサンプリレするための確率分布を計算. 対数をと, そしていく.

$$p(x_n | s_n, \lambda^{(i-1)}) = \prod_{k=1}^K P_{0i}(x_n | \lambda_k^{(i-1)})^{S_{n,k}} + \text{const.}$$

$$\log p(x_n | s_n, \lambda^{(i-1)})$$

$$= \sum_{k=1}^K S_{n,k} \log P_{0i}(x_n | \lambda_k^{(i-1)})$$

$$= \sum_{k=1}^K S_{n,k} (\lambda_n \log \lambda_k^{(i-1)} - \lambda_k^{(i-1)}) + \text{const.}$$

また,

$$\log p(s_n | \pi^{(i-1)}) = \log \text{Cat}(s_n | \pi^{(i-1)}) = \sum_{k=1}^K S_{n,k} \log \pi_k.$$

二つあわせて,

$$\begin{aligned}
& \log p(x_n | s_n, \lambda^{(i-1)}) p(s_n | \pi^{(i-1)}) \\
&= \log p(x_n | s_n, \lambda^{(i-1)}) + \log p(s_n | \pi^{(i-1)}) \\
&= \sum_{k=1}^K S_{n,k} \left(x_n \log \lambda_k^{(i-1)} - \lambda_k^{(i-1)} \right) + \sum_{k=1}^K S_{n,k} \log \pi_k^{(i-1)} + \text{const.} \\
&= \sum_{k=1}^K S_{n,k} \left(x_n \log \lambda_k^{(i-1)} - \lambda_k^{(i-1)} + \log \pi_k^{(i-1)} \right) + \text{const.}
\end{aligned}$$

制約 $\sum_{k=1}^K S_{n,k} = 1$ を考慮すると、これは s_n に関する

カテゴリリ分布（の定数倍）の対数をとったもの。

$$\therefore s_n^{(i)} \sim \text{Cat}(S_n | \gamma_n^{(i)}),$$

$$\gamma_{n,k}^{(i)} \propto \exp(x_n \log \lambda_k^{(i-1)} - \lambda_k^{(i-1)} + \log \pi_k^{(i-1)}), \quad \sum_{k=1}^K \gamma_{n,k}^{(i)} = 1.$$

- (2) について、 $\pi, \lambda = \{\lambda_1^{(i)}, \dots, \lambda_K^{(i)}\}$ をサンプルするための

条件付き分布 $p(\pi, \lambda | S^{(i)}, \mathcal{X})$ を求める。
"given to be".

先の式変形と同様にして、

$$\begin{aligned}
& p(\pi, \lambda | S^{(i)}, \mathcal{X}) \\
& \propto p(\pi, \lambda, S^{(i)}, \mathcal{X}) \quad \downarrow \text{乘法則} \\
&= p(\mathcal{X} | \pi, \lambda, S^{(i)}) p(S^{(i)} | \pi, \lambda) p(\pi | \lambda) p(\lambda) \quad \downarrow \text{独立性} \\
&= p(\mathcal{X} | S^{(i)}, \lambda) p(S^{(i)} | \pi) p(\pi) p(\lambda) \\
&= \frac{p(\mathcal{X} | S^{(i)}, \lambda) p(\lambda) p(S^{(i)} | \pi) p(\pi)}{\lambda \text{に関する項} \quad \pi \text{に関する項}}
\end{aligned}$$

$\rightarrow S^{(i)}, \mathcal{X}$: given のもとで, π と λ は条件付き独立.

別々にサンプリングを行える.

- λ の分布 $p(\lambda | S^{(i)}, \mathcal{X}) \propto p(\mathcal{X} | S^{(i)}, \lambda) p(\lambda)$ にこなす.

対数をとて計算していく.

$$\begin{aligned}
 & \log p(\lambda | S^{(i)}, \mathcal{X}) \\
 &= \log p(\mathcal{X} | S^{(i)}, \lambda) p(\lambda) + \text{const.} \quad p(\lambda) = \prod_{k=1}^K p(\lambda_k). \\
 &= \log p(\mathcal{X} | S^{(i)}, \lambda) + \log p(\lambda) + \text{const.} \\
 &= \sum_{n=1}^N \log p(x_n | s_n^{(i)}, \lambda) + \sum_{k=1}^K \log p(\lambda_k) + \text{const.} \\
 &= \sum_{n=1}^N \log \left(\prod_{k=1}^K \text{Poi}(x_n | \lambda_k)^{s_{n,k}^{(i)}} \right) + \sum_{k=1}^K \log \text{Gam}(\lambda_k | a, b) + \text{const.} \\
 &= \sum_{n=1}^N \sum_{k=1}^K s_{n,k}^{(i)} \log \text{Poi}(x_n | \lambda_k) + \sum_{k=1}^K \log \text{Gam}(\lambda_k | a, b) + \text{const.} \\
 &= \sum_{k=1}^K \left(\sum_{n=1}^N s_{n,k}^{(i)} (\lambda_k \log \lambda_k - \lambda_k) + (a-1) \log \lambda_k - b \lambda_k \right) + \text{const.} \\
 &= \sum_{k=1}^K \left(\left(\sum_{n=1}^N s_{n,k}^{(i)} x_n + a-1 \right) \log \lambda_k - \left(\sum_{n=1}^N s_{n,k}^{(i)} + b \right) \lambda_k \right) + \text{const.}
 \end{aligned}$$

$\{$ ガンマ分布のpdfの対数とした形.

$$\begin{aligned}
 & \therefore p(\lambda | S^{(i)}, \mathcal{X}) = \prod_{k=1}^K \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k), \quad \text{各 } \lambda_k \text{ は独立.} \\
 & \hat{a}_k := \sum_{n=1}^N s_{n,k}^{(i)} x_n + a, \quad \hat{b}_k := \sum_{n=1}^N s_{n,k}^{(i)} + b \quad \text{と書ける.}
 \end{aligned}$$

つまり、各 $k = 1, \dots, K$ に対して、

$$\lambda_k^{(i)} \sim \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k),$$

$$\hat{a}_k = \sum_{n=1}^N S_{n,k}^{(i)} + a, \quad \hat{b}_k = \sum_{n=1}^N S_{n,k}^{(i)} + b$$

Σサシブリング"で計算します。

- π の分布 $p(\pi | S^{(i)}, \mathcal{X}) \propto p(S^{(i)} | \pi) p(\pi)$ になります。

これも、対数をとて計算していく。

$$\log p(\pi | S^{(i)}, \mathcal{X})$$

$$= \log p(S^{(i)} | \pi) p(\pi) + \text{const.}$$

$$= \log p(S^{(i)} | \pi) + \log p(\pi) + \text{const.}$$

$$= \log \left(\prod_{n=1}^N p(s_n^{(i)} | \pi) \right) + \log p(\pi) + \text{const.}$$

$$= \sum_{n=1}^N \log \text{Cat}(s_n^{(i)} | \pi) + \log \text{Dir}(\pi | \alpha) + \text{const.}$$

$$= \sum_{n=1}^N \log \left(\prod_{k=1}^K \pi_k^{S_{n,k}^{(i)}} \right) + \sum_{k=1}^K (\alpha_k - 1) \log \pi_k + \text{const.}$$

$$= \sum_{k=1}^K \left(\sum_{n=1}^N S_{n,k}^{(i)} + \alpha_k - 1 \right) \log \pi_k + \text{const.}$$

Dirichlet 分布 pdf の対数とした形。

∴ $\pi^{(i)}$ は、以下の Dirichlet 分布からサンプリングでき：

$$\pi^{(i)} \sim \text{Dir}(\pi | \hat{\alpha}), \quad \hat{\alpha}_k := \sum_{n=1}^N S_{n,k}^{(i)} + \alpha_k \quad (k = 1, \dots, K).$$

• 以上より、Gibbsサンプリングのアルゴリズムは次のとおり：

$\lambda^{(0)}, \pi^{(0)}$ をランダムに生成；

for $i = 1, \dots, N_{\max}$ do

for $n = 1, \dots, N$ do

$$\gamma_{n,k} \propto \exp(x_n \log \lambda_k^{(i-1)} - \lambda_k^{(i-1)} + \log \pi_k^{(i-1)})$$

$$(k = 1, \dots, K), \sum_{k=1}^K \gamma_{n,k} = 1 \text{ となる } \gamma_n \text{ を } < ;$$

$$s_n^{(i)} \sim \text{Cat}(s_n | \gamma_n)$$

end for;

for $k = 1, \dots, K$ do

$$\hat{a}_k := \sum_{n=1}^N s_{n,k}^{(i)} x_n + a; \quad \hat{b}_k := \sum_{n=1}^N s_{n,k}^{(i)} + b;$$

$$\lambda_k^{(i)} \sim \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k)$$

end for;

$$\hat{\alpha}_k := \sum_{n=1}^N s_{n,k}^{(i)} + \alpha_k \quad (k = 1, \dots, K) \text{ となる } \hat{\alpha} \text{ を } < ;$$

$$\pi^{(i)} \sim \text{Dir}(\pi | \hat{\alpha})$$

end for.

4.3.3 変分推論

- $p(S, \pi, \lambda | \mathcal{X}) \approx q(S)q(\pi, \lambda)$ と、

潜在変数と分布のパラメータを分けて近似

(**変分 Bayes EM アルゴリズム**)

- $q(S)$ は

4.2.2 の公式を利用すると。

$$\log q(S)$$

$$= \mathbb{E}_{q(\lambda, \pi)} [\log p(S, \pi, \lambda, \mathcal{X})] + \text{const.}$$

$$= \mathbb{E}_{q(\lambda, \pi)} [\log p(\mathcal{X} | S, \pi, \lambda)] + \mathbb{E}_{q(\lambda, \pi)} [\log p(S | \pi, \lambda)]$$

$$+ \underbrace{\mathbb{E}_{q(\lambda, \pi)} [\log p(\pi, \lambda)]}_{\text{const.}} + \text{const.} \quad \downarrow \text{独立性}$$

$$= \mathbb{E}_{q(\lambda, \pi)} [\log p(\mathcal{X} | S, \lambda)] + \mathbb{E}_{q(\lambda, \pi)} [\log p(S | \pi)] + \text{const.}$$

$$= \int q(\lambda, \pi) \log p(\mathcal{X} | S, \lambda) d\lambda d\pi \quad \text{積分中, } \pi \text{ はここに現れない. } \int q(\lambda, \pi) d\pi = q(\lambda).$$

$$+ \int q(\lambda, \pi) \log p(S | \pi) d\lambda d\pi + \text{const.} \quad \text{積分中, } \lambda \text{ はここに現れない. } \int q(\lambda, \pi) d\lambda = q(\pi).$$

$$= \int q(\lambda) \log p(\mathcal{X} | S, \lambda) d\lambda + \int q(\pi) \log p(S | \pi) d\pi + \text{const.}$$

$$= \mathbb{E}_{q(\lambda)} [\log p(\mathcal{X} | S, \lambda)] + \mathbb{E}_{q(\pi)} [\log p(S | \pi)] + \text{const.}$$

$$\begin{aligned}
&= \mathbb{E}_{q(\lambda)} \left[\sum_{n=1}^N \log p(x_n | s_n, \lambda) \right] \\
&\quad + \mathbb{E}_{q(\pi)} \left[\sum_{n=1}^N \log p(s_n | \pi) \right] + \text{const.} \quad \downarrow \text{期待値の線形性} \\
&= \sum_{n=1}^N \left(\mathbb{E}_{q(\lambda)} [\log p(x_n | s_n, \lambda)] + \mathbb{E}_{q(\pi)} [\log p(s_n | \pi)] \right) + \text{const}
\end{aligned}$$

$\rightarrow \log q_f(S)$ は s_n に関する項の和で書ける。

$$\therefore q_f(S) = \prod_{n=1}^N q_f(s_n) \text{ と書ける。}$$

- s_n に関する項の計算をすすめていく。

$$\begin{aligned}
&\mathbb{E}_{q(\lambda)} [\log p(x_n | s_n, \lambda)] \\
&= \mathbb{E}_{q(\lambda)} \left[\log \left(\prod_{k=1}^K \text{Poi}(x_n | \lambda_k)^{s_{n,k}} \right) \right] \\
&= \mathbb{E}_{q(\lambda)} \left[\sum_{k=1}^K s_{n,k} \log \text{Poi}(x_n | \lambda_k) \right] \quad \downarrow \text{期待値の線形性} \\
&= \sum_{k=1}^K s_{n,k} \mathbb{E}_{q(\lambda)} [\log \text{Poi}(x_n | \lambda_k)] \quad \text{↑ } \lambda_k \text{のみ出でく。} \\
&= \sum_{k=1}^K s_{n,k} \mathbb{E}_{q(\lambda_k)} [x_n \log \lambda_k - \lambda_k] + \text{const.} \quad \downarrow \text{期待値の線形性} \\
&= \sum_{k=1}^K s_{n,k} \left(x_n \mathbb{E}_{q(\lambda_k)} [\log \lambda_k] - \mathbb{E}_{q(\lambda_k)} [\lambda_k] \right) + \text{const.}
\end{aligned}$$

また、第2項についても、

$$\begin{aligned}
 & \mathbb{E}_{q(\pi)}[\log p(s_n | \pi)] \\
 &= \mathbb{E}_{q(\pi)}[\log \text{Cat}(s_n | \pi)] \\
 &= \mathbb{E}_{q(\pi)}\left[\log\left(\prod_{k=1}^K \pi_k^{s_{n,k}}\right)\right] \\
 &= \mathbb{E}_{q(\pi)}\left[\sum_{k=1}^K s_{n,k} \log \pi_k\right] \quad \text{期待値の線形性} \\
 &= \sum_{k=1}^K s_{n,k} \mathbb{E}_{q(\pi)}[\log \pi_k].
 \end{aligned}$$

$$\begin{aligned}
 & \therefore \mathbb{E}_{q(\lambda)}[\log p(x_n | s_n, \lambda)] + \mathbb{E}_{q(\pi)}[\log p(s_n | \pi)] \\
 &= \sum_{k=1}^K s_{n,k} \left(x_n \mathbb{E}_{q(\lambda_k)}[\log \lambda_k] - \mathbb{E}_{q(\lambda_k)}[\lambda_k] + \mathbb{E}_{q(\pi)}[\log \pi_k] \right)
 \end{aligned}$$

カテゴリ分布のpdfの対数をとった形。 + const.

$$\begin{aligned}
 & \therefore q_p(s_n) = \text{Cat}(s_n | \gamma_n), \\
 & \gamma_{n,k} \propto \exp(x_n \mathbb{E}_{q(\lambda_k)}[\log \lambda_k] - \mathbb{E}_{q(\lambda_k)}[\lambda_k] + \mathbb{E}_{q(\pi)}[\log \pi_k]) \\
 & (k = 1, \dots, K) \text{ 且 } \sum_{k=1}^K \gamma_{n,k} = 1.
 \end{aligned}$$

含まれている期待値計算を行うには、 $q_p(\pi)$, $q_p(\lambda_k)$ の形を明らかにする必要があるのを、ここは後回し。

- $q_p(\pi, \lambda)$ について。

$$\begin{aligned}
 & \log q_p(\pi, \lambda) \\
 &= \mathbb{E}_{q(s)}[\log p(S, \pi, \lambda, X)] + \text{const.}
 \end{aligned}$$

$$\begin{aligned}
&= \mathbb{E}_{q(s)}[\log p(X|S, \pi, \lambda)] + \mathbb{E}_{q(s)}[\log p(S|\pi, \lambda)] \\
&\quad + \mathbb{E}_{q(s)}[\log p(\pi|\lambda)] + \mathbb{E}_{q(s)}[\log p(\lambda)] + \text{const.} \\
&= \mathbb{E}_{q(s)}[\log p(X|S, \lambda)] + \mathbb{E}_{q(s)}[\log p(S|\pi)] \\
&\quad + \mathbb{E}_{q(s)}[\log p(\pi)] + \mathbb{E}_{q(s)}[\log p(\lambda)] + \text{const.} \\
&= \mathbb{E}_{q(s)}[\log p(X|S, \lambda)] + \log p(\lambda) \\
&\quad + \mathbb{E}_{q(s)}[\log p(S|\pi)] + \log p(\pi) + \text{const.}
\end{aligned}$$

↓ 独立性

→ λ に関する項と π に関する項が完全に分離している。

$$\therefore q(\pi, \lambda) = q(\lambda)q(\pi) \quad : \text{独立}.$$

- λ に関する項について。

$$\begin{aligned}
&\log q(\lambda) \\
&= \mathbb{E}_{q(s)}[\log p(X|S, \lambda)] + \log p(\lambda) + \text{const.} \\
&= \mathbb{E}_{q(s)}\left[\sum_{n=1}^N \log p(x_n|s_n, \lambda) \right] + \log p(\lambda) + \text{const.} \\
&= \sum_{n=1}^N \mathbb{E}_{q(s)}[\log p(x_n|s_n, \lambda)] + \log p(\lambda) + \text{const.} \\
&= \sum_{n=1}^N \mathbb{E}_{q(s)}[\log p(x_n|s_n, \lambda)] + \log p(\lambda) + \text{const.} \\
&= \sum_{n=1}^N \mathbb{E}_{q(s_n)}[\log p(x_n|s_n, \lambda)] + \log p(\lambda) + \text{const.}
\end{aligned}$$

↑ 期待値。
線形性

↑ 期待値となる
ものは、 s_n について。
独立性。

$$= \sum_{n=1}^N \mathbb{E}_{q(S_n)} \left[\log \left(\prod_{k=1}^K \text{Poi}(x_n | \lambda_k)^{S_{n,k}} \right) \right] + \sum_{k=1}^K \log p(\lambda_k) + \text{const.}$$

$$= \sum_{n=1}^N \mathbb{E}_{q(S_n)} \left[\sum_{k=1}^K S_{n,k} \log \text{Poi}(x_n | \lambda_k) \right] + \sum_{k=1}^K \log p(\lambda_k) + \text{const.}$$

期待値
線形性

$$= \sum_{k=1}^K \left(\sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] \log \text{Poi}(x_n | \lambda_k) + \log \text{Gam}(\lambda_k | a, b) \right) + \text{const.}$$

$$= \sum_{k=1}^K \left(\sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] (x_n \log \lambda_k - \lambda_k) + (a-1) \log \lambda_k - b \lambda_k \right) + \text{const.}$$

$$= \sum_{k=1}^K \left(\left(\sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] x_n + a-1 \right) \log \lambda_k - \left(\sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] + b \right) \lambda_k \right)$$

ガム分布のpdfの対数とした形

+ const.

$$\therefore q(\lambda) = \prod_{k=1}^K \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k), \quad \text{各 } \lambda_k \text{ は独立.}$$

$$\hat{a}_k := \sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] x_n + a, \quad \hat{b}_k := \sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] + b$$

と書ける.

- πに関する項をつけて.

$$\log q(\pi)$$

$$= \mathbb{E}_{q(s)} [\log p(s | \pi)] + \log p(\pi) + \text{const.}$$

$$= \mathbb{E}_{q(s)} \left[\sum_{n=1}^N \log p(s_n | \pi) \right] + \log p(\pi) + \text{const.}$$

期待値
線形性

$$= \sum_{n=1}^N \mathbb{E}_{q(S_n)} [\log \text{Cat}(s_n | \pi)] + \log \text{Dir}(\pi | \alpha) + \text{const.}$$

$$\begin{aligned}
&= \sum_{n=1}^N \mathbb{E}_{q(S_n)} \left[\log \left(\prod_{k=1}^K \pi_k^{S_{n,k}} \right) \right] + \sum_{k=1}^K (\alpha_k - 1) \log \pi_k + \text{const.} \\
&= \sum_{n=1}^N \mathbb{E}_{q(S_n)} \left[\sum_{k=1}^K S_{n,k} \log \pi_k \right] + \sum_{k=1}^K (\alpha_k - 1) \log \pi_k + \text{const.} \\
&\stackrel{\text{期待値}}{\downarrow} \quad \text{線形性} \\
&= \sum_{n=1}^N \sum_{k=1}^K \mathbb{E}_{q(S_n)} [S_{n,k}] \log \pi_k + \sum_{k=1}^K (\alpha_k - 1) \log \pi_k + \text{const.} \\
&= \sum_{k=1}^K \left(\sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] + \alpha_k - 1 \right) \log \pi_k + \text{const.}
\end{aligned}$$

Dirichlet分布のpdfの対数とした形

$$\begin{aligned}
&\therefore q(\pi) = \text{Dir}(\pi | \hat{\alpha}), \\
&\hat{\alpha}_k := \sum_{n=1}^N \mathbb{E}_{q(S_n)} [S_{n,k}] + \alpha_k \quad (k = 1, \dots, K).
\end{aligned}$$

→ $q(\lambda_k)$, $q(\pi)$ とも、それぞれ事前分布と同じ種類の分布になつた。

・各種期待値について。

$$q(\lambda_k) = \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k) \text{なる}^{\circ},$$

$$\mathbb{E}_{q(\lambda_k)} [\lambda_k] = \frac{\hat{a}_k}{\hat{b}_k}, \quad \mathbb{E}_{q(\lambda_k)} [\log \lambda_k] = \psi(\hat{a}_k) - \log \hat{b}_k.$$

$$q(\pi) = \text{Dir}(\pi | \hat{\alpha}) \text{なる}^{\circ},$$

$$\mathbb{E}_{q(\pi)} [\log \pi_k] = \psi(\hat{\alpha}_k) - \psi\left(\sum_{i=1}^K \hat{\alpha}_i\right).$$

$$q(S_n) = \text{Cat}(S_n | \gamma_n) \text{なる}^{\circ},$$

$$\mathbb{E}_{q(S_n)} [S_{n,k}] = \gamma_{n,k}.$$

• 結局、分布は以下の通り：

- $q_f(s_n) = \text{Cat}(s_n | \gamma_n),$

$$\gamma_{n,k} \propto \exp\left(x_n(\psi(\hat{\alpha}_k) - \log \hat{b}_k) - \frac{\hat{a}_k}{\hat{b}_k} + \psi(\hat{\alpha}_k) - \psi\left(\sum_{i=1}^K \hat{\alpha}_i\right)\right)$$

$\text{P1: } \sum_{k=1}^K \gamma_{n,k} = 1.$

- $q_f(\lambda_k) = \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k)$

$$\hat{a}_k := \sum_{n=1}^N \gamma_{n,k} x_n + a, \quad \hat{b}_k := \sum_{n=1}^N \gamma_{n,k} + b.$$

- $q_f(\pi_\Gamma) = \text{Dir}(\pi_\Gamma | \hat{\alpha}),$

$$\hat{\alpha}_k := \sum_{n=1}^N \gamma_{n,k} + \alpha_k \quad (k=1, \dots, K).$$

- 以上より、後づけ推論のアルゴリズムは次のとおり：

```

 $q_p(\lambda_k) = \text{Gam}(\lambda_k | \hat{a}_k, \hat{b}_k), q_p(\pi) = \text{Dir}(\pi | \hat{\alpha})$  と initialize;

for  $i = 1, \dots, N_{\max}$  do ← 適当に上限を設けていき
    for  $n = 1, \dots, N$  do
         $\gamma_{n,k} \propto \exp\left(x_n(\psi(\hat{a}_k) - \log \hat{b}_k) - \hat{a}_k/\hat{b}_k + \psi(\hat{\alpha}_k) - \psi\left(\sum_{i=1}^k \hat{\alpha}_i\right)\right)$  ( $k = 1, \dots, K$ ),
         $\sum_{k=1}^K \gamma_{n,k} = 1$  となる  $\gamma_n$  をつくす
    end for;

    for  $k = 1, \dots, K$  do
         $\hat{a}_k := \sum_{n=1}^N \gamma_{n,k} x_n + a$ ;
         $\hat{b}_k := \sum_{n=1}^N \gamma_{n,k} + b$ 
    end for;

     $\hat{\alpha}_k := \sum_{n=1}^N \gamma_{n,k} + \alpha_k$  ( $k = 1, \dots, K$ ) となる  $\hat{\alpha}$  をつくす;
     $\pi \sim \text{Dir}(\pi | \hat{\alpha})$ 
end for.

```

- ここでも、終了条件は ELBO を採用することもできます。

ELBO を計算してみる。

$$\mathcal{L}[q]$$

$$= \mathbb{E}_{q(s)q(\pi, \lambda)} \left[\log \frac{p(s, \pi, \lambda, x)}{q(s)q(\pi, \lambda)} \right] \quad \downarrow \text{乗法則}$$

$$= \mathbb{E}_{q(s)q(\pi, \lambda)} \left[\log \frac{p(x|s, \pi, \lambda)p(s|\pi, \lambda)p(\pi|\lambda)p(\lambda)}{q(s)q(\pi, \lambda)} \right]$$

$$= \mathbb{E}_{q(s)q(\pi, \lambda)} \left[\log \frac{p(x|s, \lambda)p(s|\pi)p(\pi)p(\lambda)}{q(s)q(\pi, \lambda)} \right] \quad \downarrow \text{独立性}$$

$$= \mathbb{E}_{q(s)q(\pi)q(\lambda)} \left[\log \frac{p(x|s, \lambda)p(s|\pi)p(\pi)p(\lambda)}{q(s)q(\pi)q(\lambda)} \right] \quad \downarrow \begin{array}{l} \text{logの性質} \\ \text{期待値の線形性} \end{array}$$

$$= \mathbb{E}_{q(s)q(\pi)q(\lambda)} \left[\log p(x|s, \lambda) \right] + \mathbb{E}_{q(s)q(\pi)q(\lambda)} \left[\log p(s|\pi) \right] \quad \downarrow \begin{array}{l} \text{独立性} \\ \text{独立性} \end{array}$$

$$- \mathbb{E}_{q(s)q(\pi)q(\lambda)} \left[\log q(s) \right] + \mathbb{E}_{q(s)q(\pi)q(\lambda)} \left[\log \frac{p(\lambda)}{q(\lambda)} \right] \quad \downarrow \begin{array}{l} \text{独立性} \\ \text{独立性} \end{array}$$

$$+ \mathbb{E}_{q(s)q(\pi)q(\lambda)} \left[\log \frac{p(\pi)}{q(\pi)} \right] \quad \downarrow \lambda, s \text{ は独立}$$

$$= \mathbb{E}_{q(s)q(\lambda)} \left[\log p(x|s, \lambda) \right] + \mathbb{E}_{q(s)q(\pi)} \left[\log p(s|\pi) \right]$$

$$- \mathbb{E}_{q(s)} \left[\log q(s) \right] + \mathbb{E}_{q(\lambda)} \left[\log \frac{p(\lambda)}{q(\lambda)} \right] + \mathbb{E}_{q(\pi)} \left[\log \frac{p(\pi)}{q(\pi)} \right]$$

$$\begin{aligned}
&= \mathbb{E}_{q(\lambda)} \left[\sum_{n=1}^N \log p(x_n | s_n, \lambda) \right] + \mathbb{E}_{q(\lambda)q(\pi)} \left[\sum_{n=1}^N \log p(s_n | \pi) \right] \\
&\quad - \mathbb{E}_{q(\lambda)} \left[\sum_{n=1}^N \log q(s_n) \right] - \text{KL}[q(\lambda) \| p(\lambda)] \\
&\quad - \text{KL}[q(\pi) \| p(\pi)] \\
&= \sum_{n=1}^N \mathbb{E}_{q(s_n)q(\lambda)} \left[\log p(x_n | s_n, \lambda) \right] + \sum_{n=1}^N \mathbb{E}_{q(s_n)q(\pi)} \left[\log p(s_n | \pi) \right] \\
&\quad - \sum_{n=1}^N \mathbb{E}_{q(s_n)} \left[\log q(s_n) \right] - \text{KL}[q(\lambda) \| p(\lambda)] \\
&\quad - \text{KL}[q(\pi) \| p(\pi)].
\end{aligned}$$

- 各項の計算は、分布の形や“かた”についているので、やれれば“できる”。
 - $\mathcal{L}[q]$ の最初の 3 項：データに対する当てはまり具合や、分布 $q(\lambda)$ の望ましさを表す。
 - $\mathcal{L}[q]$ の最後の 2 項： $q(\lambda), q(\pi)$ が事前分布 $p(\lambda), p(\pi)$ から大きく離れるのを防ぐ“正則化項”。
- 逐分推論アルゴリズムは、自然に過適合を防ぐ“ようになつてゐる”！

4.3.4 崩壊型 Gibbsサンプリング

- まずは、同時分布 $p(S, \pi, \lambda, \mathcal{X})$ から、分布のパラメータ π, λ

を周辺化により除去する：

$$p(S, \mathcal{X}) = \int p(S, \pi, \lambda, \mathcal{X}) d\lambda d\pi.$$

$\rightarrow S$ は $p(S | \mathcal{X})$ からサンプリングすればよい。

パラメータの事後分布などは、サンプリングされた S から計算可能。

- 周辺化後は、各 S_n が互いに依存関係をもつ。

(各 S_n は $\pi: \text{given}$ のもとでは条件付で独立であった)

\rightarrow 全ての S_n を同時にサンプリングするのは計算量的にキツい：

$S = \{S_1, \dots, S_N\} \subseteq \{0,1\}^K$ のとりうる組合せ数： K^N 通り。

\rightarrow 周辺化後のモデルの事後分布 $p(S | \mathcal{X})$ に対して、Gibbs

サンプリングを適用して、各 S_n をはりはりにサンプルする。

- $S_{\setminus n}^{(i)} := \{S_1^{(i)}, \dots, S_{n-1}^{(i)}, S_{n+1}^{(i-1)}, \dots, S_N^{(i-1)}\}$,

$$\mathcal{X}_{\setminus n} := \{x_1, \dots, x_{n-1}, x_{n+1}, \dots, x_N\} \quad \text{とする。}$$

$$S_n^{(i)} \sim p(S_n | \mathcal{X}, S_{\setminus n}^{(i)}) \text{ としたい。}$$

$$\rightarrow p(S_n | \mathcal{X}, S_{\setminus n}^{(i)}) \text{ を計算していく。}$$

$$\begin{aligned}
 & p(s_n | \mathcal{X}, S_{in}^{(i)}) \\
 & \propto p(s_n, \mathcal{X}, S_{in}^{(i)}) \quad \downarrow \text{Bayes' Thm.} \\
 & = p(x_n, \mathcal{X}_{in}, s_n, S_{in}^{(i)}) \quad \downarrow \text{乗法則} \quad \begin{array}{l} \text{グラフィカルモデルを参考する} \\ s_n \text{は } \mathcal{X}_{in} \text{ の各 } x_i \text{ と条件付で独立} \\ \text{E} \text{ と分ける} \end{array} \\
 & = p(x_n | \mathcal{X}_{in}, s_n, S_{in}^{(i)}) p(\mathcal{X}_{in} | s_n, S_{in}^{(i)}) p(s_n | S_{in}^{(i)}) p(S_{in}^{(i)}) \\
 & = p(x_n | \mathcal{X}_{in}, s_n, S_{in}^{(i)}) \underbrace{p(\mathcal{X}_{in} | S_{in}^{(i)})}_{s_n \text{ に依存する}} \underbrace{p(s_n | S_{in}^{(i)})}_{S_{in}^{(i)} \text{ に依存する}} p(S_{in}^{(i)}) \\
 & \propto p(x_n | \mathcal{X}_{in}, s_n, S_{in}^{(i)}) p(s_n | S_{in}^{(i)}).
 \end{aligned}$$

• $p(s_n | S_{in}^{(i)})$ は, $S_{in}^{(i)}$: given のときの s_n の予測分布と解釈可能:

$$p(s_n | S_{in}^{(i)}) = \int p(s_n | \pi) p(\pi | S_{in}^{(i)}) d\pi.$$

$p(\pi | S_{in}^{(i)})$ は $S_{in}^{(i)}$: given のときの「 π の事後分布」.

この計算は "3.2.2 カテゴリ分布の学習と予測" で既にやった!

$$\therefore p(\pi | S_{in}^{(i)}) = \text{Dir}(\pi | \hat{\alpha}_{in}^{(i)}),$$

$$\hat{\alpha}_{in,k}^{(i)} := \sum_{n'=1}^{n-1} S_{n',k}^{(i)} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} + \alpha_k \quad (k = 1, \dots, K).$$

よって, "3.2.2 カテゴリ分布の学習と予測" の予測分布の結果より,

$$\begin{aligned}
 p(s_n | S_{in}^{(i)}) &= \int \text{Cat}(s_n | \pi) \text{Dir}(\pi | \hat{\alpha}_{in}^{(i)}) d\pi \\
 &= \text{Cat}(s_n | \gamma_{in}),
 \end{aligned}$$

$$\gamma_{in,k} \propto \hat{\alpha}_{in,k}^{(i)}, \quad \sum_{k=1}^K \gamma_{in,k} = 1.$$

- $p(x_n | \mathcal{X}_{\text{in}}, \mathcal{S}_n, S_{\text{in}}^{(i)})$ は, $\mathcal{X}_{\text{in}}, S_{\text{in}}^{(i)}$: given のときの x_n の
予測分布のようなもの:

$$p(x_n | \mathcal{X}_{\text{in}}, \mathcal{S}_n, S_{\text{in}}^{(i)}) = \int p(x_n | \mathcal{S}_n, \lambda) p(\lambda | \mathcal{X}_{\text{in}}, S_{\text{in}}^{(i)}) d\lambda.$$

$p(\lambda | \mathcal{X}_{\text{in}}, S_{\text{in}}^{(i)})$ は $\mathcal{X}_{\text{in}}, S_{\text{in}}^{(i)}$: given のときの「 λ の事後分布」.

$$p(\lambda | \mathcal{X}_{\text{in}}, S_{\text{in}}^{(i)}) \propto p(\lambda, \mathcal{X}_{\text{in}}, S_{\text{in}}^{(i)})$$

$$= p(\mathcal{X}_{\text{in}} | S_{\text{in}}^{(i)}, \lambda) p(S_{\text{in}}^{(i)} | \lambda) p(\lambda) \quad \downarrow \text{独立性}$$

$$= p(\mathcal{X}_{\text{in}} | S_{\text{in}}^{(i)}, \lambda) \underbrace{p(S_{\text{in}}^{(i)})}_{\lambda \text{による}} p(\lambda)$$

$$\propto p(\mathcal{X}_{\text{in}} | S_{\text{in}}^{(i)}, \lambda) p(\lambda).$$

$$\begin{aligned}
 & \log p(\mathcal{X}_{\text{in}} | S_{\text{in}}^{(i)}, \lambda) p(\lambda) \\
 &= \log p(\mathcal{X}_{\text{in}} | S_{\text{in}}^{(i)}, \lambda) + \log p(\lambda) \\
 &= \sum_{n'=1}^{n-1} \log p(x_{n'} | S_{n'}^{(i)}, \lambda) + \sum_{n'=n+1}^N \log p(x_{n'} | S_{n'}^{(i-1)}, \lambda) + \log p(\lambda) \\
 &= \sum_{n'=1}^{n-1} \sum_{k=1}^K S_{n',k}^{(i)} \log \text{Poi}(x_{n'} | \lambda_k) + \sum_{n'=n+1}^N \sum_{k=1}^K S_{n',k}^{(i-1)} \log \text{Poi}(x_{n'} | \lambda_k) \\
 &\quad + \sum_{k=1}^K \log \text{Gam}(\lambda_k | a, b) \\
 &= \sum_{k=1}^K \left(\sum_{n'=1}^{n-1} S_{n',k}^{(i)} (x_{n'} \log \lambda_k - \lambda_k) + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} (x_{n'} \log \lambda_k - \lambda_k) \right. \\
 &\quad \left. + (a-1) \log \lambda_k - b \lambda_k \right) + \text{const.}
 \end{aligned}$$

$$= \sum_{k=1}^K \left(\left(\sum_{n'=1}^{n-1} S_{n',k}^{(i)} x_{n'} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} x_{n'} + a - 1 \right) \log \lambda_k \right. \\ \left. - \left(\sum_{n'=1}^{n-1} S_{n',k}^{(i)} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} + b \right) \lambda_k \right) + \text{const.}$$

ヤンマー分布のpdfの対数をとった形

$$\therefore p(\lambda | \mathcal{X}_{\setminus n}, S_{\setminus n}^{(i)}) = \prod_{k=1}^K \text{Gam}(\lambda_k | \hat{a}_{\setminus n, k}^{(i)}, \hat{b}_{\setminus n, k}^{(i)}),$$

$$\hat{a}_{\setminus n, k}^{(i)} := \sum_{n'=1}^{n-1} S_{n',k}^{(i)} x_{n'} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} x_{n'} + a,$$

$$\hat{b}_{\setminus n, k}^{(i)} := \sum_{n'=1}^{n-1} S_{n',k}^{(i)} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} + b$$

と書ける。これを用いて、 λ を積分除去し、 $p(x_n | \mathcal{X}_{\setminus n}, S_n, S_{\setminus n}^{(i)})$ を計算する。ただし、 $S_n = (\underbrace{0, \dots, 1, \dots, 0}_k)^T$ ($S_{n,k} = 1$) とすると、

$$p(x_n | \mathcal{X}_{\setminus n}, S_{n,k} = 1, S_{\setminus n}^{(i)}) \\ = \int p(x_n | \lambda_k) p(\lambda_k | \mathcal{X}_{\setminus n}, S_{\setminus n}^{(i)}) d\lambda_k \\ = \int \text{Poi}(x_n | \lambda_k) \text{Gam}(\lambda_k | \hat{a}_{\setminus n, k}^{(i)}, \hat{b}_{\setminus n, k}^{(i)}) d\lambda_k \quad \downarrow \text{3.2.3で述べた} \\ = \text{NB}(x_n | \hat{a}_{\setminus n, k}^{(i)}, (\hat{b}_{\setminus n, k}^{(i)} + 1)^{-1}).$$

よって、

$$p(x_n | \mathcal{X}_{\setminus n}, S_n, S_{\setminus n}^{(i)}) \\ = \int p(x_n | S_n, \lambda) p(\lambda | \mathcal{X}_{\setminus n}, S_{\setminus n}^{(i)}) d\lambda \\ = \int \prod_{k=1}^K \text{Poi}(x_n | \lambda_k)^{S_{n,k}} \text{Gam}(\lambda_k | \hat{a}_{\setminus n, k}^{(i)}, \hat{b}_{\setminus n, k}^{(i)}) d\lambda$$

$$\begin{aligned}
&= \prod_{k=1}^K \int \text{Poi}(x_n | \lambda_k)^{S_{n,k}} \text{Gam}(\lambda_k | \hat{\alpha}_{in,k}^{(i)}, \hat{b}_{in,k}^{(i)}) d\lambda_k \\
&= \prod_{k=1}^K \left(\int \text{Poi}(x_n | \lambda_k) \text{Gam}(\lambda_k | \hat{\alpha}_{in,k}^{(i)}, \hat{b}_{in,k}^{(i)}) d\lambda_k \right)^{S_{n,k}} \\
&= \prod_{k=1}^K \text{NB}(x_n | \hat{\alpha}_{in,k}^{(i)}, (\hat{b}_{in,k}^{(i)} + 1)^{-1})^{S_{n,k}}. \\
\bullet \quad &\log p(S_n | \mathcal{X}, S_{in}^{(i)}) \\
&= \log p(x_n | \mathcal{X}_{in}, S_n, S_{in}^{(i)}) + \log p(S_n | S_{in}^{(i)}) + \text{const.} \\
&= \sum_{k=1}^K S_{n,k} \log \text{NB}(x_n | \hat{\alpha}_{in,k}^{(i)}, (\hat{b}_{in,k}^{(i)} + 1)^{-1}) + \sum_{k=1}^K S_{n,k} \log \gamma_{in,k} + \text{const.} \\
&= \sum_{k=1}^K S_{n,k} \log \gamma_{in,k} \text{NB}(x_n | \hat{\alpha}_{in,k}^{(i)}, (\hat{b}_{in,k}^{(i)} + 1)^{-1}) + \text{const.} \\
&= \sum_{k=1}^K S_{n,k} \log \hat{\alpha}_{in,k}^{(i)} \text{NB}(x_n | \hat{\alpha}_{in,k}^{(i)}, (\hat{b}_{in,k}^{(i)} + 1)^{-1}) + \text{const.}
\end{aligned}$$

$\gamma_{in,k} \propto \hat{\alpha}_{in,k}^{(i)}$

カテゴリ分布のpmf. の対数ととてよ。

以上より、 $S_n^{(i)}$ のサンプリングは、次のように行えればいい：

$$S_n^{(i)} \sim p(S_n | \mathcal{X}, S_{in}^{(i)}) = \text{Cat}(S_n | \zeta_{in}),$$

$$\zeta_{in,k} \propto \hat{\alpha}_{in,k}^{(i)} \text{NB}(x_n | \hat{\alpha}_{in,k}^{(i)}, (\hat{b}_{in,k}^{(i)} + 1)^{-1}), \quad \sum_{k=1}^K \zeta_{in,k} = 1.$$

- 次が成立してることに注意する。

$$\hat{\alpha}_{in+1,k}^{(i)}$$

$$\begin{aligned}
&= \sum_{n'=1}^n S_{n',k}^{(i)} + \sum_{n'=n+2}^N S_{n',k}^{(i-1)} + \alpha_k = \sum_{n'=1}^{n-1} S_{n',k}^{(i)} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} + \alpha_k + S_{n,k}^{(i)} - S_{n+1,k}^{(i-1)} \\
&= \hat{\alpha}_{in,k}^{(i)} + S_{n,k}^{(i)} - S_{n+1,k}^{(i-1)}. \quad (n = 1, \dots, N-1)
\end{aligned}$$

$$\hat{\alpha}_{1,k}^{(i)}$$

$$= \sum_{n'=2}^N S_{n',k}^{(i-1)} + \alpha_k = \sum_{n'=1}^{N-1} S_{n',k}^{(i-1)} + \alpha_k + S_{N,k}^{(i-1)} - S_{1,k}^{(i-1)}$$

$$= \hat{\alpha}_{1,N,k}^{(i-1)} + S_{N,k}^{(i-1)} - S_{1,k}^{(i-1)}$$

$$\hat{\alpha}_{1,(n+1),k}^{(i)}$$

$$= \sum_{n'=1}^n S_{n',k}^{(i)} x_{n'} + \sum_{n'=n+2}^N S_{n',k}^{(i-1)} x_{n'} + a$$

$$= \sum_{n'=1}^{n-1} S_{n',k}^{(i)} x_{n'} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} x_{n'} + a + S_{n,k}^{(i)} x_n - S_{n+1,k}^{(i-1)} x_{n+1}$$

$$= \hat{\alpha}_{1,n,k}^{(i)} + S_{n,k}^{(i)} x_n - S_{n+1,k}^{(i-1)} x_{n+1}. \quad (n=1, \dots, N-1)$$

$$\hat{\alpha}_{1,k}^{(i)}$$

$$= \sum_{n'=2}^N S_{n',k}^{(i-1)} x_{n'} + a$$

$$= \sum_{n'=1}^{N-1} S_{n',k}^{(i-1)} x_{n'} + a + S_{N,k}^{(i-1)} x_N - S_{1,k}^{(i-1)} x_1$$

$$= \hat{\alpha}_{1,N,k}^{(i-1)} + S_{N,k}^{(i-1)} x_N - S_{1,k}^{(i-1)} x_1$$

$$\hat{b}_{1,(n+1),k}^{(i)}$$

$$= \sum_{n'=1}^n S_{n',k}^{(i)} + \sum_{n'=n+2}^N S_{n',k}^{(i-1)} + b$$

$$= \sum_{n'=1}^{n-1} S_{n',k}^{(i)} + \sum_{n'=n+1}^N S_{n',k}^{(i-1)} + b + S_{n,k}^{(i)} - S_{n+1,k}^{(i-1)}$$

$$= \hat{b}_{1,n,k}^{(i)} + S_{n,k}^{(i)} - S_{n+1,k}^{(i-1)}. \quad (n=1, \dots, N-1)$$

$$\begin{aligned}
 & \hat{b}_{1,k}^{(i)} \\
 &= \sum_{n'=2}^N S_{n',k}^{(i-1)} + b \\
 &= \sum_{n'=1}^{N-1} S_{n',k}^{(i-1)} + b + S_{N,k}^{(i-1)} - S_{1,k}^{(i-1)} \\
 &= \hat{b}_{1,N,k}^{(i-1)} + S_{N,k}^{(i-1)} - S_{1,k}^{(i-1)}.
 \end{aligned}$$

- 実装上は、上記に注意することで、計算速度とメモリの面で効率的。

崩壊型 Gibbsサンプリングのアルゴリズムを以下にまとめよ：

```

S = {S_1^{(0)}, …, S_N^{(0)}} ε initialize;
for k = 1, …, K do
     $\hat{\alpha}_k := \sum_{n=1}^N S_{n,k}^{(0)} + \alpha_k;$ 
     $\hat{a}_k := \sum_{n=1}^N S_{n,k}^{(0)} x_n + a;$ 
     $\hat{b}_k := \sum_{n=1}^N S_{n,k}^{(0)} + b$ 
end for;

for i = 1, …, N_max do ← 適当に上限を設けよう
    for n = 1, …, N do
        for k = 1, …, K do
             $\hat{\alpha}_k := \hat{\alpha}_k - S_{n,k}^{(i-1)};$ 
             $\hat{a}_k := \hat{a}_k - S_{n,k}^{(i-1)} x_n;$ 
             $\hat{b}_k := \hat{b}_k - S_{n,k}^{(i-1)}$ 
    end for;
end for;

```

end for;

for $k = 1, \dots, K$ do

$$\zeta_k := \hat{\alpha}_k \text{NB}(x_n | \hat{a}_k, (\hat{b}_k + 1)^{-1})$$

end for;

$$\sum_{k=1}^K \zeta_k = 1 \text{となる} \Rightarrow \zeta \text{を正规化};$$

$$s_n^{(i)} \sim \text{Cat}(\zeta_n | \zeta);$$

for $k = 1, \dots, K$ do

$$\hat{\alpha}_k := \hat{\alpha}_k + s_{n,k}^{(i)}; \quad \hat{a}_k := \hat{a}_k + s_{n,k}^{(i)} x_n; \quad \hat{b}_k := \hat{b}_k + s_{n,k}^{(i)}$$

end for

end for

end for.

§4.4 Gauss混合モデルにおける推論

4.4.1 Gauss混合モデル

- ・ K クラスタある D -次元データの生成過程を表現.
- ・ $\mu := \{\mu_1, \dots, \mu_K\}$, $\Lambda := \{\Lambda_1, \dots, \Lambda_K\}$, $\Theta_k = \{\mu_k, \Lambda_k\}$: パラメータ.
クラスタ k に対する観測モデル: $p(x_n | \Theta_k) := \mathcal{N}(x_n | \mu_k, \Lambda_k^{-1})$

→ 混合分布における条件付き分布は.

$$p(x_n | s_n, \mu, \Lambda) = \prod_{k=1}^K \mathcal{N}(x_n | \mu_k, \Lambda_k^{-1})^{s_{n,k}}$$

s_n によって, K つの Gauss 分布の一つが指定される.

- ・ μ, Λ に対して, 事前分布を設定する.

Gauss 分布の共役事前分布 \rightarrow Gauss-Wishart 分布.

$$p(\mu_k, \Lambda_k) := NW(\mu_k, \Lambda_k | m, \beta, \nu, W)$$

$$= \mathcal{N}(\mu_k | m, (\beta \Lambda_k)^{-1}) \mathcal{W}(\Lambda_k | \nu, W)$$

クラスターごとに
違うパラメータに
変化する

$$m \in \mathbb{R}^D, \beta \in \mathbb{R}_{>0}, \nu > D - 1, W \in M_D(\mathbb{R}), W > 0: パラメータ.$$

- ・ s_n に対する事前分布は, $p(s_n | \pi) := \text{Cat}(s_n | \pi)$,

π に対する事前分布は, $p(\pi) := \text{Dir}(\pi | \alpha)$

($\alpha: パラメータ$) と設定する.

4.4.2 Gibbsサンプリング

- 事後分布 $p(S, \mu, \Lambda, \pi | \mathcal{X})$ もうサンプリングとする。

次のように、パラメータと潜在変数を分けてサンプリング：

$$S^{(i)} \sim p(S | \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}, \mathcal{X}) \quad - (1)$$

$$\mu^{(i)}, \Lambda^{(i)}, \pi^{(i)} \sim p(\mu, \Lambda, \pi | S^{(i)}, \mathcal{X}) \quad - (2)$$

- (1) で、 $p(S | \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}, \mathcal{X})$ を求めよ。

$$\begin{aligned} & p(S | \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}, \mathcal{X}) \\ & \propto p(S, \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}, \mathcal{X}) \\ & = p(\mathcal{X} | S, \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}) p(S | \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}) \\ & \times \underbrace{p(\mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)})}_{\text{S: 独立}} \quad \downarrow \text{独立性} \\ & \propto p(\mathcal{X} | S, \mu^{(i-1)}, \Lambda^{(i-1)}) p(S | \pi^{(i-1)}) \\ & = \prod_{n=1}^N p(x_n | s_n, \mu^{(i-1)}, \Lambda^{(i-1)}) p(s_n | \pi^{(i-1)}). \end{aligned}$$

$\rightarrow \mu^{(i-1)}, \Lambda^{(i-1)}, \pi^{(i-1)}, \mathcal{X}$: given " , 各 s_n は条件付で独立。

- $\log p(x_n | s_n, \mu^{(i-1)}, \Lambda^{(i-1)})$

$\hookrightarrow s_n$ のサンプリングと
考慮している。

$$= \sum_{k=1}^K s_{n,k} \log \mathcal{N}(x_n | \mu_k^{(i-1)}, (\Lambda_k^{(i-1)})^{-1})$$

$$= \sum_{k=1}^K s_{n,k} \left(-\frac{1}{2} (x_n - \mu_k^{(i-1)})^T \Lambda_k^{(i-1)} (x_n - \mu_k^{(i-1)}) + \frac{1}{2} \log (\det \Lambda_k^{(i-1)}) \right) + \text{const}$$

$$\cdot \log p(s_n | \pi^{(i-1)}) = \log \text{Cat}(s_n | \pi^{(i-1)}) = \sum_{k=1}^K s_{n,k} \log \pi_k.$$

である。

$$\begin{aligned} & \log p(x_n | s_n, \mu^{(i-1)}, \Lambda^{(i-1)}) p(s_n | \pi^{(i-1)}) \\ &= \log p(x_n | s_n, \mu^{(i-1)}, \Lambda^{(i-1)}) + \log p(s_n | \pi^{(i-1)}) \\ &= \sum_{k=1}^K s_{n,k} \left(-\frac{1}{2} (\mathbf{x}_n - \boldsymbol{\mu}_k^{(i-1)})^\top \boldsymbol{\Lambda}_k^{(i-1)} (\mathbf{x}_n - \boldsymbol{\mu}_k^{(i-1)}) \right. \\ &\quad \left. + \frac{1}{2} \log(\det \boldsymbol{\Lambda}_k^{(i-1)}) + \log \pi_k \right) + \text{const.} \end{aligned}$$

制約 $\sum_{k=1}^K s_{n,k} = 1$ を考慮すると、これは s_n は K 個の

カテゴリリ分布（の定数倍）の対数をとったもの。

$$\therefore s_n^{(i)} \sim \text{Cat}(s_n | \gamma_n^{(i)}),$$

$$\begin{aligned} \gamma_{n,k}^{(i)} &\propto \exp \left(-\frac{1}{2} (\mathbf{x}_n - \boldsymbol{\mu}_k^{(i-1)})^\top \boldsymbol{\Lambda}_k^{(i-1)} (\mathbf{x}_n - \boldsymbol{\mu}_k^{(i-1)}) \right. \\ &\quad \left. + \frac{1}{2} \log(\det \boldsymbol{\Lambda}_k^{(i-1)}) + \log \pi_k \right), \end{aligned}$$

$$\sum_{k=1}^K \gamma_{n,k}^{(i)} = 1.$$

$$\circ (2) \text{ として}, p(\mu, \Lambda, \pi | S^{(i)}, \mathcal{X}) \text{ を求めよ}.$$

$$p(\mu, \Lambda, \pi | S^{(i)}, \mathcal{X})$$

$$\propto p(\mu, \Lambda, \pi, S^{(i)}, \mathcal{X})$$

$$= p(\mathcal{X} | \mu, \Lambda, \pi, S^{(i)}) p(S^{(i)} | \mu, \Lambda, \pi) p(\mu, \Lambda | \pi) p(\pi)$$

独立性

$$= p(\mathcal{X} | S^{(i)}, \mu, \Lambda) p(S^{(i)} | \pi) p(\mu, \Lambda) p(\pi)$$

$$= \underbrace{p(\mathcal{X} | S^{(i)}, \mu, \Lambda) p(\mu, \Lambda)}_{\mu, \Lambda \text{ は } \mathcal{X} \text{ の独立}} \underbrace{p(S^{(i)} | \pi) p(\pi)}_{\pi \text{ は } \mathcal{X} \text{ の独立}}$$

$\rightarrow S^{(i)}, \mathcal{X}$: given \mathcal{X} , (μ, Λ) と π は 条件付き独立:

$$p(\mu, \Lambda | S^{(i)}, \mathcal{X}) \propto p(\mathcal{X} | S^{(i)}, \mu, \Lambda) p(\mu, \Lambda),$$

$$p(\pi | S^{(i)}, \mathcal{X}) \propto p(S^{(i)} | \pi) p(\pi),$$

$$p(\mu, \Lambda, \pi | S^{(i)}, \mathcal{X}) = p(\mu, \Lambda | S^{(i)}, \mathcal{X}) p(\pi | S^{(i)}, \mathcal{X}).$$

- $\log p(\mu, \Lambda | S^{(i)}, \mathcal{X})$

$$= \log p(\mathcal{X} | S^{(i)}, \mu, \Lambda) + \log p(\mu, \Lambda) + \text{const.}$$

$$= \sum_{n=1}^N \log p(x_n | s_n^{(i)}, \mu, \Lambda) + \sum_{k=1}^K \log p(\mu_k, \Lambda_k) + \text{const.}$$

$$= \sum_{n=1}^N \sum_{k=1}^K s_{n,k}^{(i)} \log \mathcal{N}(x_n | \mu_k, \Lambda_k^{-1}) + \sum_{k=1}^K \log \text{NW}(\mu_k, \Lambda_k | \text{im}, \beta, \nu, W) + \text{const.}$$

$$= \sum_{k=1}^K \left(\sum_{n=1}^N s_{n,k}^{(i)} \log \mathcal{N}(x_n | \mu_k, \Lambda_k^{-1}) + \log \text{NW}(\mu_k, \Lambda_k | \text{im}, \beta, \nu, W) \right) + \text{const.}$$

$$\rightarrow p(\mu, \Lambda | S^{(i)}, \mathcal{X}) = \prod_{k=1}^K p(\mu_k, \Lambda_k | S^{(i)}, \mathcal{X}),$$

$$\log p(\mu_k, \Lambda_k | S^{(i)}, \mathcal{X})$$

$$= \sum_{n=1}^N s_{n,k}^{(i)} \log \mathcal{N}(x_n | \mu_k, \Lambda_k^{-1}) + \log \text{NW}(\mu_k, \Lambda_k | \text{im}, \beta, \nu, W) + \text{const.}$$

$$P(\mu_k, \Lambda_k | S^{(i)}, \mathcal{X}) = P(\mu_k | \Lambda_k, S^{(i)}, \mathcal{X}) P(\Lambda_k | S^{(i)}, \mathcal{X}) - (*)$$

であるが、Gauss-Wishart分布の推論について述べよう。

μ_k の分布を求めてあとは Λ_k の分布を求める。

- $\log P(\mu_k, \Lambda_k | S^{(i)}, \mathcal{X}) \quad (= \log P(\mu_k | \Lambda_k, S^{(i)}, \mathcal{X}) + \text{const.})$
 $= -\frac{1}{2} \sum_{n=1}^N S_{n,k}^{(i)} \left((\mathbf{x}_n - \mu_k)^T \Lambda_k (\mathbf{x}_n - \mu_k) - \underbrace{\log(\det \Lambda_k)}_{\text{const.}} \right)$
 $+ \log \mathcal{N}(\mu_k | \mathbf{l}_m, (\beta \Lambda_k)^{-1}) + \underbrace{\log W(\Lambda_k | \nu, W)}_{\text{const.}} + \text{const.}$
 $= -\frac{1}{2} \sum_{n=1}^N S_{n,k}^{(i)} (\mathbf{x}_n - \mu_k)^T \Lambda_k (\mathbf{x}_n - \mu_k)$
 $- \frac{1}{2} \left(\beta (\mu_k - \mathbf{l}_m)^T \Lambda_k (\mu_k - \mathbf{l}_m) - \underbrace{\log(\det(\beta \Lambda_k))}_{\text{const.}} \right) + \text{const.}$
 $= -\frac{1}{2} \left(\sum_{n=1}^N S_{n,k}^{(i)} \underbrace{(\mathbf{x}_n^T \Lambda_k \mathbf{x}_n)}_{\text{const.}} - 2\mu_k^T \Lambda_k \mathbf{x}_n + \mu_k^T \Lambda_k \mu_k \right)$
 $\quad \beta (\mu_k^T \Lambda_k \mu_k - 2\mu_k^T \Lambda_k \mathbf{l}_m + \underbrace{\mathbf{l}_m^T \Lambda_k \mathbf{l}_m}_{\text{const.}}) + \text{const.}$
 $= -\frac{1}{2} \left(\mu_k^T \left(\sum_{n=1}^N S_{n,k}^{(i)} + \beta \right) \Lambda_k \mu_k - 2\mu_k^T \Lambda_k \left(\sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n + \beta \mathbf{l}_m \right) \right) + \text{const.}$

$$\therefore \hat{\mu}_k^{(i)} \sim P(\mu_k | \Lambda_k, S^{(i)}, \mathcal{X}) = \mathcal{N}(\mu_k | \hat{\mathbf{l}}_m, (\hat{\beta}_k \Lambda_k)^{-1}),$$

$$\hat{\beta}_k := \sum_{n=1}^N S_{n,k}^{(i)} + \beta, \quad \hat{\mathbf{l}}_m := \hat{\beta}_k^{-1} \left(\sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n + \beta \mathbf{l}_m \right).$$

- $P(\Lambda_k | S^{(i)}, \mathcal{X})$ を求める。(*) 使う

$$\log P(\Lambda_k | S^{(i)}, \mathcal{X})$$

$$\begin{aligned}
&= \log p(\mu_k, \Lambda_k | S^{(i)}, \mathcal{X}) - \log p(\mu_k | \Lambda_k, S^{(i)}, \mathcal{X}) \\
&= -\frac{1}{2} \sum_{n=1}^N S_{n,k}^{(i)} \left((\mathbf{x}_n - \mu_k)^T \Lambda_k (\mathbf{x}_n - \mu_k) - \log(\det \Lambda_k) \right) \\
&\quad - \frac{1}{2} \left(\beta (\mu_k - \mathbf{m})^T \Lambda_k (\mu_k - \mathbf{m}) - \log(\det(\beta \Lambda_k)) \right) \\
&\quad + \log \mathcal{W}(\Lambda_k | \nu, W) - \log \mathcal{N}(\mu_k | \hat{\mathbf{m}}_k, (\hat{\beta}_k \Lambda_k)^{-1}) + \text{const.} \\
&= -\frac{1}{2} \left(\mu_k^T \left(\sum_{n=1}^N S_{n,k}^{(i)} + \beta \right) \Lambda_k \mu_k - 2 \mu_k^T \Lambda_k \left(\sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n + \beta \mathbf{m} \right) \right) \\
&\quad - \frac{1}{2} \sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n^T \Lambda_k \mathbf{x}_n - \frac{1}{2} \beta \mathbf{m}^T \Lambda_k \mathbf{m} \\
&\quad + \frac{1}{2} \sum_{n=1}^N S_{n,k}^{(i)} \log(\det \Lambda_k) + \frac{1}{2} \log(\det \Lambda_k) + \frac{1}{2} D \log \beta \\
&\quad + \frac{\nu - D - 1}{2} \log(\det \Lambda_k) - \frac{1}{2} \text{tr}(W^{-1} \Lambda_k) \quad \leftarrow \log \mathcal{W}(\Lambda_k | \nu, W) \text{ による} \\
&\quad + \frac{1}{2} \left((\mu_k - \hat{\mathbf{m}}_k)^T (\hat{\beta}_k \Lambda_k) (\mu_k - \hat{\mathbf{m}}_k) - \log(\det(\hat{\beta}_k \Lambda_k)) \right) + \text{const.} \\
&= -\frac{1}{2} \left(\mu_k^T (\hat{\beta}_k \Lambda_k) \mu_k - 2 \mu_k^T (\hat{\beta}_k \Lambda_k) \hat{\mathbf{m}}_k \right) \\
&\quad - \frac{1}{2} \left(\text{tr} \left(\sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n \mathbf{x}_n^T \Lambda_k \right) + \text{tr}(\beta \mathbf{m} \mathbf{m}^T \Lambda_k) \right) \\
&\quad + \frac{1}{2} \sum_{n=1}^N S_{n,k}^{(i)} \log(\det \Lambda_k) + \frac{1}{2} \log(\det \Lambda_k) \\
&\quad + \frac{\nu - D - 1}{2} \log(\det \Lambda_k) - \frac{1}{2} \text{tr}(W^{-1} \Lambda_k) \\
&\quad + \frac{1}{2} \left(\mu_k^T (\hat{\beta}_k \Lambda_k) \mu_k - 2 \mu_k^T (\hat{\beta}_k \Lambda_k) \hat{\mathbf{m}}_k + \hat{\mathbf{m}}_k^T (\hat{\beta}_k \Lambda_k) \hat{\mathbf{m}}_k \right) \\
&\quad - \frac{1}{2} \log(\det \Lambda_k) - \frac{1}{2} D \log \hat{\beta}_k + \text{const.} \\
&\quad \text{const.}
\end{aligned}$$

前回→
 式変形と
 関数計算

$$= \frac{1}{2} \left(\sum_{n=1}^N S_{n,k}^{(i)} + \nu - D - 1 \right) \log(\det \Lambda_k) \\ - \frac{1}{2} \text{tr} \left(\left(\sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n \mathbf{x}_n^T + \beta \mathbf{m} \mathbf{m}^T - \hat{\beta}_k \hat{\mathbf{m}}_k \hat{\mathbf{m}}_k^T + W^{-1} \right) \Lambda_k \right) + \text{const.}$$

$$\therefore \Lambda_k^{(i)} \sim p(\Lambda_k | S^{(i)}, \mathcal{X}) = \mathcal{W}(\Lambda_k | \hat{\nu}_k, \hat{W}_k),$$

$$\hat{W}_k^{-1} := \sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n \mathbf{x}_n^T + \beta \mathbf{m} \mathbf{m}^T - \hat{\beta}_k \hat{\mathbf{m}}_k \hat{\mathbf{m}}_k^T + W^{-1},$$

$$\hat{\nu}_k := \sum_{n=1}^N S_{n,k}^{(i)} + \nu.$$

・ 以上より、各 k に対して、

$$\Lambda_k^{(i)} \sim \mathcal{W}(\Lambda_k | \hat{\nu}_k, \hat{W}_k) \text{ とします},$$

$$\mu_k^{(i)} \sim \mathcal{N}(\mu_k | \hat{\mathbf{m}}_k, (\hat{\beta}_k \Lambda_k^{(i)})^{-1})$$

とするとして "サンプリング" で "さす".

$$\bullet \quad \pi^{(i)} \sim p(\pi | S^{(i)}, \mathcal{X}) \propto p(S^{(i)} | \pi) p(\pi)$$

であるが、これは Poisson 混合モデルのときと同じ算済み:

$$\pi^{(i)} \sim \text{Dir}(\pi | \hat{\alpha}), \hat{\alpha}_k := \sum_{n=1}^N S_{n,k}^{(i)} + \alpha_k \quad (k = 1, \dots, K).$$

・ 以上より、Gibbs サンプリングのアルゴリズムは次のとおり:

$\mu^{(0)}, \Lambda^{(0)}, \pi^{(0)}$ をランダムに生成;

for $i = 1, \dots, N_{\max}$ do

for $n = 1, \dots, N$ do

$$\gamma_{n,k} \propto \exp\left(-\frac{1}{2}\left(\mathbf{x}_n - \boldsymbol{\mu}_k^{(i-1)}\right)^T \Lambda_k^{(i-1)} \left(\mathbf{x}_n - \boldsymbol{\mu}_k^{(i-1)}\right)\right)$$

$$+ \frac{1}{2} \log(\det \Lambda_k^{(i-1)}) + \log \pi_k \quad (k = 1, \dots, K)$$

$$\sum_{k=1}^K \gamma_{n,k} = 1 \text{ となる } \gamma_n \text{ を } < ;$$

$$s_n^{(i)} \sim \text{Cat}(s_n | \gamma_n)$$

end for;

for $k = 1, \dots, K$ do

$$\hat{\beta}_k := \sum_{n=1}^N S_{n,k}^{(i)} + \beta ; \quad \hat{m}_k := \hat{\beta}_k^{-1} \left(\sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n + \beta m \right) ;$$

$$\hat{W}^{-1} := \sum_{n=1}^N S_{n,k}^{(i)} \mathbf{x}_n \mathbf{x}_n^T + \beta m m^T - \hat{\beta}_k \hat{m}_k \hat{m}_k^T + W^{-1} ;$$

$$\hat{v}_k := \sum_{n=1}^N S_{n,k}^{(i)} + v ;$$

$$\Lambda_k^{(i)} \sim \mathcal{W}(\Lambda_k | \hat{v}_k, \hat{W}_k) ;$$

$$\boldsymbol{\mu}_k^{(i)} \sim \mathcal{N}(\boldsymbol{\mu}_k | \hat{m}_k, (\hat{\beta}_k \Lambda_k^{(i)})^{-1})$$

end for;

$$\hat{\alpha}_k := \sum_{n=1}^N S_{n,k}^{(i)} + \alpha_k \quad (k = 1, \dots, K) \text{ となる } \hat{\alpha} \text{ を } < ;$$

$$\pi^{(i)} \sim \text{Dir}(\pi | \hat{\alpha})$$

end for.